

密级： 非密级

南昌大学

NANCHANG UNIVERSITY

学士学位论文

THESIS OF BACHELOR

(2021—2025 年)



题 目 基于多通道语义融合的 DGA 域名样本不平衡分类
优化方法研究

学 院： 软件学院 系 网络空间安全

专业班级： 网络空间安全 2103 班

学生姓名： 舒萌 学号： 8008121332

指导教师： 邵国林 职称： 校聘副研究员

起讫日期： 2024 年 11 月至 2025 年 5 月

南昌大学

学士学位论文原创性申明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所取得的研究成果。除了文中特别加以标注引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写的成果。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式表明。本人完全意识到本声明的法律后果由本人承担。

作者签名：舒萌

日期：2024 年 5 月 26 日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权南昌大学可以将本论文的全部内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

保密□，在 年解密后适用本授权书。

本学位论文属于

不保密☑。

（请在以上相应方框内打“√”）

作者签名：舒萌

日期：2024 年 5 月 26 日

导师签名：邵同林

日期：2024 年 5 月 26 日

基于多通道语义融合的 DGA 域名样本不平衡分类优化方法研究

专 业：网络空间安全

学 号：8008121332

学生姓名：舒萌

指导教师：邵国林

摘要

僵尸网络（Botnet）通过动态生成域名（DGA）隐匿命令与控制（C&C）服务器，显著增强了隐蔽性和生存能力，成为网络安全领域的重大威胁。当前 DGA 检测面临严峻的类别不平衡问题，虽已有数据和算法层面的解决方案，但对特定难分类、少数类 DGA 家族识别仍有不足。

本文研究发现，难分类问题的根源在于不同 DGA 家族生成的域名在语义表征空间存在高度重叠。为此，本文提出一种新颖的基于预训练多通道自编码器（PMAE-DGA）的表征学习方法，通过跨通道注意力机制融合 TLD 偏好、多尺度序列模式及统计特征等多源异构信息，并联合优化重构任务与分类任务，保留 DGA 关键语义信息并增强类间区分性，从而实现 DGA 生成策略敏感的表征学习能力。实验表明，PMAE-DGA 在 OSINT DGA 和 360 DGA 数据集上，在保持 Micro F1 指标相当或小幅提升的同时，Macro-F1 指标均显著优于三类经典不平衡算法（ROS、SMOTE、Cost-Sensitive）及三个 SOTA 方法（LSMT.PQDO、LSTM.MI、DeepDGA），尤其对难分类和少数类样本的检测性能提升显著（F1 最高提升 240.5%）。

本文首次指出 DGA 域名难区分的语义混淆问题，进行了体系化的特征提取工作和工具构建，提出了新颖的 MAE 表征学习方法，并通过全面对比实验证明了方法的性能优势。研究成果为应对 DGA 检测的语义混淆与样本不平衡问题提供了新思路。

关键词：僵尸网络；DGA 检测；不平衡学习；表征学习；多通道自编码器

PMAE-DGA: A Pretrained Multichannel Autoencoder for DGA Representation Learning with Sensitivity to Generation Mechanism in Imbalanced Botnet Detection

Abstract

Botnet Conceals Command and Control (C&C) Servers via Dynamically Generated Domains (DGA), Significantly Enhancing Stealth and Survivability, Posing a Major Threat to Cybersecurity. Current DGA detection faces severe class imbalance issues. Although solutions exist at both data and algorithmic levels, challenges persist in identifying specific hard-to-classify and minority DGA families.

This study reveals that the root cause of the classification difficulty lies in the high overlap of semantic representations among domains generated by different DGA families in the feature space. To address this, we propose a novel representation learning method based on a Pre-trained Multi-channel Autoencoder (PMAE-DGA). By leveraging a cross-channel attention mechanism, our approach fuses multi-source heterogeneous information, including TLD preferences, multi-scale sequential patterns, and statistical features, while jointly optimizing reconstruction and classification tasks. This preserves critical semantic information of DGAs and enhances inter-class discriminability, thereby achieving DGA-generation-strategy-sensitive representation learning. Experiments demonstrate that PMAE-DGA significantly outperforms three classic imbalance-handling algorithms (ROS/SMOTE/Cost-Sensitive) and three state-of-the-art (SOTA) methods (LSTM-PQDO/LSTM-MI/DeepDGA) in Macro-F1 on both OSINT DGA and 360 DGA datasets, while maintaining comparable or slightly improved Micro-F1. Notably, it achieves substantial performance gains for hard-to-classify and minority-class samples (up to 240.5% improvement in F1-score).

This work is the first to identify the semantic confusion problem in DGA domain classification, systematically conducts feature extraction and tool construction, proposes a novel MAE-based representation learning approach, and validates its superiority through comprehensive comparative experiments. The findings provide new insights for addressing semantic ambiguity and class imbalance in DGA detection.

Keyword: Botnet; DGA detection; Imbalanced learning; Representation learning; Multichannel autoencoder

目录

摘要	I
Abstract	II
第一章 绪论	1
1.1 背景与意义	1
1.2 研究现状	3
1.2.1 DGA 检测研究现状	3
1.2.2 DGA 不平衡学习研究现状	5
1.3 论文组织结构	6
第二章 相关理论与技术基础	8
2.1 DGA 域名生成技术	8
2.1.1 基于域名生成算法 (DGA) 的僵尸网络	8
2.1.2 DGA 域名生成策略	9
2.2 特征提取技术	9
2.2.1 基于统计的特征提取	9
2.2.2 基于深度学习的特征提取	10
2.3 长短期记忆网络 (LSTM)	10
2.4 多模态模型	11
2.4.1 基本概念	11
2.4.2 多模态特征融合	11
2.5 预训练模型	12
2.6 注意力机制	13
第三章 问题分析与模型构建	15
3.1 DGA 检测优化分析	15
3.1.1 DGA 数据不平衡原因分析	15
3.1.2 表征学习可行性探究	15
3.2 模型设计与实现	17
3.2.1 模型总体架构	17
3.2.2 多通道特征提取模块	18
3.2.2.1 多维度特征提取方案概览	18
3.2.2.2 多通道特征预处理	21
3.2.2.3 多通道特征向量学习	22
3.2.3 预训练的表征学习模型	23
3.2.3.1 总体过程概述	23

3.2.3.2 多通道语义特征融合	23
3.2.3.3 DGA 自身关键语义特征学习（重构任务）	24
3.2.3.4 DGA 类间区分性特征学习（分类任务）	25
3.2.4 DGA 检测模型	25
3.2.4.1 数据集样本表征转换	26
3.2.4.2 分类基模型选取与构建	26
3.2.4.3 不平衡学习方案选择与构建	26
第四章 实验分析	27
4.1 实验设定	27
4.1.1 数据集介绍	27
4.1.2 实验环境	28
4.1.3 评价指标	29
4.2 参数分析与选取	30
4.2.1 权重分析	30
4.2.2 特征通道选择	31
4.2.3 基分类器选择	32
4.2.4 不平衡优化算法选择	33
4.3 消融实验	34
4.3.1 学习模块增量验证实验	34
4.3.2 预训练的表征学习模块增益效果分析	37
4.4 对比实验	38
4.4.1 对比方法选取	38
4.4.2 对比实验结果分析	39
第五章 系统设计与实现	43
5.1 系统设计	43
5.1.1 系统需求分析	43
5.1.2 系统功能模块划分与功能描述	43
5.2 系统实现与测试	44
5.2.1 数据集分布展示模块	44
5.2.2 多通道特征提取模块	46
5.2.3 预训练表征模型模块	49
5.2.4 DGA 检测器模块	51
第六章 总结与展望	55
6.1 工作总结	55
6.2 研究展望	55

参考文献	56
致谢	60

第一章 绪论

1.1 背景与意义

互联网的快速发展深刻改变了经济、社会和日常生活，但同时也带来了严峻的网络安全挑战。其中，僵尸网络作为最具破坏性的威胁之一，通过受恶意软件感染的主机集群在攻击者远程控制下实施大规模网络犯罪活动。这些被操控的“僵尸设备”能够发起分布式拒绝服务（DDoS）攻击、传播垃圾邮件、窃取敏感数据以及进行未经授权的加密货币挖矿等恶意行为，对网络生态构成系统性威胁[7]。根据2023年INTERPOL全球威胁评估报告，僵尸网络相关攻击占关键基础设施攻击事件的43%，造成的年均经济损失超过1200亿美元，其规模化、自动化的攻击特性使得单次攻击可波及数百万终端设备。

僵尸网络的核心运作机制依赖于命令与控制（C&C）服务器的通信架构。早期僵尸网络为C&C服务器配置静态IP地址和域名，这种方法存在明显的缺陷。一旦恶意程序被反编译，或者通过流量分析发现C&C的IP地址，该IP就会被列入黑名单，控制者将面临失去对整个僵尸网络控制的风险^[22]。为规避检测，攻击者开始使用域名生成算法（DGA）来隐匿C&C服务器地址。DGA可以动态生成海量伪随机域名，攻击者在需要发动攻击时随机选取其中少数域名注册为C&C服务器地址。而僵尸设备与攻击者运行同一套共同商定好的DGA算法，生成相同的备选域名并不断尝试进行连接，当某个查询成功解析，便可以与C&C服务器建立通信。C&C服务器可以很好地隐藏在这些伪随机域名中，即使部分域名被封锁，攻击者也可快速切换到新域名。这极大地增加了检测的难度，显著提升了僵尸网络的隐蔽性和生存能力。

当前，DGA技术已发展出多代变种，其生成的域名在字符分布、语义模式等方面与良性域名的差异日益模糊，这使得高精度检测面临巨大挑战。DGA的随机性和多变性使得黑名单难以更新，早期基于规则匹配和黑名单的防御手段在面对DGA生成的恶意域名时已失效，安全企业不得不转向更复杂的检测方案^{[30][32]}。在此背景下，如何准确识别DGA域名并有效切断Bot与C&C服务器之间的通信渠道，已成为打击现代僵尸网络的关键技术挑战，相关研究也引起了广泛的研究关注^[29-30]。

早期DGA僵尸网络检测通常使用基于上下文的检测方法，依赖于DNS流量或DNS日志的分析^{[1][2][3][4][5][7][8]}。然而，这种检测方法往往依赖于较长时间窗口内的统计特征分析，这需要更大的数据存储空间作为支撑，还增加了计算复杂度，导致其实时检测能力受到严重制约。且此类方法主要针对二分类场景，在

面对实际应用中更为复杂的多分类任务时，其检测精度和泛化性能仍有待验证。近年来，通过直接分析域名字符串的特征来检测DGA域名的研究兴起。这类方法无需上下文信息，对隐私的侵犯更小，能够实现更加高效的实时监测^[11]。基于机器学习的实时检测方法^[9-11]从域名中提取不同特征并输入到机器学习算法中进行分类。然而特征提取是一项困难的任务，为避免特征工程，基于深度学习的DGA实时监测方法在网络安全领域得到了应用^[13-23]。

基于深度学习的检测方法能够实现自动特征挖掘，相较于其他方法检测方法效果出色也更适用于多分类任务场景。但是，当前DGA检测面临着数据不平衡的困扰，而深度学习架构对每个类别的所有样本一视同仁，更容易受到类别不平衡问题的影响^[13]。然而很多深度学习模型^[15-23]未考虑类别间样本数量的差异，在面临样本量极不均衡的数据集以及新兴的DGA变体时表现不佳。但是在网络安全领域，样本数量较少的不常见DGA类别需要更加警惕，因为黑客会利用不常见的DGA来增加成功入侵的概率^[31]。

为解决不平衡场景下分类器偏向多样本DGA家族，牺牲少样本类别分类性能的问题，许多研究被提出。针对数据集不平衡问题，目前主流的通用解决方法主要基于数据层面^[26]和算法层面^{[6][13][20][27][28][29][30]}，基于数据层面的解决方案主要采用重采样来平衡数据，如过采样。而基于算法层面的解决方案主要通过调整超参数来平衡各类别的权重，或者调整一些训练策略来平衡各类别的影响，如代价敏感学习。这些方法取得了一定成效，然而本文深入分析前沿模型的误分类样本发现，传统不平衡学习方法虽然能提升整体检测性能，但对特定DGA家族的识别仍存在明显不足。本文发现这一问题的本质在于不同DGA家族生成的域名在语义表征空间存在重叠。然而，这些DGA家族在生成策略上却存在本质差异，暗示着在更细粒度的特征空间中可能存在可区分的模式。这一发现为改进检测模型提供了重要方向。

受此启发，为进一步优化DGA分类器在不平衡场景下对难分类和少数类的检测性能，本文提出了一种基于预训练多通道自编码器的DGA表征学习方法（PMAE-DGA），旨在解决DGA检测中因生成机制差异和类别不平衡导致的语义混淆与检测性能下降问题。该方法采用LSTM网络构建多通道特征提取模块，从TLD偏好、字符序列、n-gram模式及统计特征等多个维度捕获DGA域名的生成策略敏感特征。接着利用跨通道注意力机制与自编码器预训练框架实现多源异构特征的深度融合。其中，自编码器通过联合优化重构损失与分类损失，既保留了域名生成机制的关键语义信息，又增强了类间区分性表征能力。基于预训练得到的融合表征，进一步采用机器学习分类器进行下游不平衡多分类任务，

并通过集成代价敏感学习优化少数类检测性能，最终构建了一个能够同时应对语义混淆与样本不平衡的DGA检测模型。本文在OSINT DGA^[37]和360 DGA^[38]两个主流公开数据集上验证了PMAE-DGA方法的效果，实验结果表明PMAE-DGA的Micro-F1和Macro-F1指标均优于经典不平衡算法及LSTM.PQDO、DeepDGA等SOTA方法，同时PMAE-DGA在两个主流数据集上显著提升了难以分类的小样本DGA家族及语义混淆域名的检测精度，充分证明了PMAE-DGA表征学习的有效性以及其在不平衡场景下的优越性。本文方法不仅为突破现有DGA检测瓶颈提供了新的技术路径，同时提出的表征学习框架还可拓展至其他网络安全任务（如恶意软件分类、异常流量检测），具有广泛的学术价值和产业应用前景。

1.2 研究现状

1.2.1 DGA 检测研究现状

近年来，基于DGA的僵尸网络的检测和分类得到广泛研究。本文系统梳理了该领域现有研究中的关键技术和方法，主要涵盖传统检测方法、基于机器学习的方法以及基于深度学习的方法三大类。

（1）传统方法

DGA僵尸网络检测的传统技术通常依赖于分析DNS流量或DNS日志，也即基于上下文的检测方法。这类方法利用DNS流量为DGA检测提供辅助信息特征。Kwon等人^[1]提出了一种名为PsyBoG的方法，利用信号处理技术和频谱密度测量技术来分析用户域名查询行为，并基于时间序列关系检测非法域名，同时提高了处理速度。其检测率为95%，并以 0.1% 的误报率识别出 23 个未知和 26 个已知的恶意软件家族。Bisio等人^[2]开发了一种基于网络监测和语言特征分析的DGA僵尸网络检测算法。他们的方法在检测40个DGA域名家族时实现了92.67%的准确率。Fang等人^[3]通过表征每个IP地址的DNS查询的时间序列模式来探索域名之间的时间相似性，从而检测DGA。Zang等人^[4]通过分析域名的行为，如节奏行为、周期性行为、访问稳定行为和服务多样性行为来识别DGA。在尝试与C2 服务器建立连接时，DGA僵尸网络会生成海量的域名来绕过黑名单的检测。而这些生成的域名中，仅有极少数会被实际注册，被感染的主机会频繁发起对大量不存在域名（即返回NXDOMAIN响应）的查询。利用这一特性，Lei等人^[5]尝试使用二分图来分析DNS流量和DNS查询的时间序列模式，然后采用图嵌入技术来表征域名。

然而上述传统方法需要在更大的时间窗口内获取统计信息，需要足够的数据存储空间，难以实现实时检测^[22]。且此类方法多用于二分类问题，在多分类问题中的适用性尚未得到展示。

（2）基于机器学习的方法

基于机器学习的检测现有工作可分为回顾式和实时式^[6]。类似传统检测方法，回顾式方法使用上下文感知特征，依赖于已收集的历史数据进行分析。Antonakakis等人^[7]一种基于两种聚类算法的DGA分类，基于域名组成相似性以及查询这些域名的机器组来进行聚类，然后将生成的聚类分配给已知的DGA僵尸网络模型。Wang等人^[8]引入了一种名为DBod的方法，该方法利用感染相同DGA的主机具有相似DNS查询行为这一特征来检测DGA域名并使用聚类方法来区分受僵尸网络攻击的集群和普通集群。他们的方法在检测僵尸网络方面实现了超过99%的准确率。

近年来，基于机器学习的实时检测方法被引入，并在DGA僵尸网络检测得到广泛运用。此类无上下文的机器学习方法直接从域名中提取不同特征并输入到机器学习算法中，实现了更高效的分类。Schuppe等人^[9]利用随机森林构建了一个基于支持向量机（SVM）和随机森林（RF）的FANCI分类器，该方法提取了12个结构特征、7个语言特征和22个统计特征来检测由59种DGA生成的恶意域名。Alaeiyan等人^[10]利用域名的字符分布、随机性属性和可发音性属性来检测DGA。Drichel等人^[11]提出了一种基于特征且无上下文的DGA多分类器EXPLAIN，该方法从域名中提取76个特征用于机器学习，并在DGA分类中实现了81%的准确率且具有很强的实时分类能力。上述实时式机器学习检测方法资源消耗更少，对隐私的侵犯也更小，然而语言特性存在潜在的缺陷，恶意攻击者可以轻易绕过这些特征，同时此类方法也难以适应新出现的DGA家族。

另外，有研究提出新方法以规避二者缺陷，AlSabeh等人^[12]提出一种新框架，利用P4交换机，在数据平面中采用混合的上下文感知和上下文无关特征提取技术并使用线速紧凑型机器学习（ML）分类器进行DGA检测。同时开发了一种网络内机制以提取结构和统计特征，比最先进的技术快数百至数千微秒。这在保护用户隐私的同时还减少了控制平面与特征提取和预处理相关的开销。

（3）基于深度学习的方法

人工特征提取耗时且容易遇到特征问题，为避免特征工程，基于深度学习的方法开始兴起。长短期记忆网络（LSTM）能够很好地学习字符之间的上下文关系，Woodbridge等人^[13]首次将深度学习技术用于域名分类，使用词嵌入技术将域名向量化，然后基于LSTM对域名进行分类。该方法表现出色。Lison和Mavroeidis^[14]采用了一种类似的长短期记忆（LSTM）方法并在更大规模的数据集上进行了训练和测试。Curtin等人^[15]引入了一种循环神经网络（RNN）模型，与辅助信息相结合来检测DGA域名。由于循环神经网络需要依赖前一步的结果，

训练和检测速度较慢，卷积神经网络（CNN）开始被用于DGA域名检测。Huang等人^[16]使用n-gram对域名进行向量化，并用多层残差卷积神经网络对DGA域名进行分类。Xu等人^[17]提出了n-CBDC模型，通过将域名字符串转换为n元语法表示作为深度卷积神经网络（CNN）模型的输入来检测基于DGA的域名。

近年来，许多研究应用了深度神经网络的混合模型来提高检测性。Highnam等人^[18]将卷积神经网络（CNN）和长短期记忆网络（LSTM）相结合来检测DGA。Liang等人^[19]发现域名的长度对DGA域名检测模型的性能有影响，提出了一个异构的DGA检测模型HAGDetector极大地提高了检测性能。该模型提出了三种适应域名长度的特征提取方法并基于这些特征提取方法设计了不同的检测结构。超短DGA基域名检测模块采用并行多路卷积来处理语义特征，中等长度DGA基域名检测模块被设计为一种基于卷积神经网络（CNN）的新结构，用于处理提取的n元语法特征。超长DGA基域名检测模块使用随机森林（RF）来学习人工构建的特征。Ravi等人^[20]利用孪生神经网络训练了一种新型分类器，无需NXDomain信息和反向工程即可检测基于DGA的僵尸网络。

一些研究将注意力机制引入了DGA分类任务。Tuan等人^[21]结合短期记忆网络（LSTM）和注意力机制，针对二分类和多分类，分别提出了LA_Bin07和LA_Mul07两种新模型，这两种模型都表现出色。Zhao等人^[22]提出了一种用于DGA域分类任务的多头自注意力卷积网络方法。该方法使用浅层卷积神经网络来提取域字符的隐藏特征，采用不同输入值的多头自注意力机制，有效地获得字符与提取的隐含特征之间的关系。Ding等人^[23]提出了一种基于混合嵌入和Transformer的深度学习模型，从字符级词嵌入和二元语法级词嵌入的组合中并行提取特征，并使用多头注意力方法进行DGA检测和分类。

1.2.2 DGA 不平衡学习研究现状

当前主流的基于深度学习的DGA检测模型避免了繁琐的特征工程工作，相较于其他检测方法效果更加出色。然而，这些DGA检测器仍受DGA类别不平衡的困扰，在面临样本量极不均衡的数据集以及新兴的DGA变体时表现不佳，对于小样本类别分类准确率低。早在研究^[13]中，Woodbridge等人^[13]就发现LSTM方法未能正确识别某些家族，他们将此归因于数据集中某些家族的样本量过小，检测器无法进行有意义的学习，且某些家族很容易被分类器误认为是与之类似的家族。Lison和Mavroeidis^[14]采用了一种类似的基于长短期记忆网络（LSTM）的方法并在更大规模的数据集上进行了训练和测试。他们的观察结果与Woodbri

dge等人^[13]的结论一致，即训练好的LSTM网络在识别占比大的DGA家族时表现出色，但在识别少数类时效果不佳。

为解决在训练样本不足的情况下所出现的问题，许多研究被提出。针对数据集不平衡问题，目前主流的通用解决方法主要基于数据层面和算法层面。基于数据层面的解决方案主要采用重采样来平衡数据，常用的方法有过采样、欠采样以及两者综合的混合采样。最广泛使用的过采样方法是少数样本的随机复制和合成少数过采样技术（SMOTE）^[24]，然而随机复制的方法耗时且容易导致过拟合，SMOTE适合高维数据，并且对噪声敏感。而欠采样方法训练时间短但可能会丢失与潜在的关键信息^[25]。目前将数据层面的再平衡算法运用到DGA检测中的研究较少。Chen等人^[26]提出了一种基于长短期记忆网络的属性和数量依赖优化（LSTM.PQDO）方法，该方法迭代重采样比例的最优解，以启发式方式在正确方向上围绕初始解搜索更好的解，从而实现重采样比例的动态优化，最终实验结果与未优化的LSTM算法相比，所提出算法获得的Macro-AVG F1分数提高13.94%。

近年来，多数针对数据集不平衡问题的DGA检测的研究多采用基于算法层面的解决方案。基于算法层面的解决方案主要通过调整超参数来平衡各类别的权重，或者调整一些训练策略来平衡各类别的影响^[30]。Woodbridge等人^[13]将研究的30个DGA分成11个超家族来解决类别不平衡问题。Tran等人^[27]首次提出了成本敏感型LSTM.MI算法。该算法将成本项引入到LSTM的反向传播机制中，以增强LSTM对不平衡问题的鲁棒性。与成本不敏感型LSTM相比，他们的方法在准确率和召回率方面均提高了7%。成本敏感算法开始被广泛的运用于DGA检测领域（例如^[6]^[20]^[28]）。Hu等人^[29]关注DGA家族中严重数据不平衡问题，重点研究了在训练样本不足的情况下基于孪生网络准确检测DGA的方法。他们提出名为DGAD-SN的检测方法，首次引入对比学习，并采用孪生网络框架构建特征提取器，利用有限的训练样本挖掘域名字符串中字符之间的隐含关系信息。最终实验表明，DGAD-SN在识别小规模DGA家族或新兴DGA变体方面优于最先进的DGA检测器。Fan等人^[30]引入长尾概念，提出数据平衡审查方法（DBRM）以缩小类别间的样本量差异，从而生成一个相对平衡的用于迁移学习的数据集并通过迁移预训练知识来扩充小样本类别的数据。他们还提出了知识蒸馏迁移模型（KDTM）以缓解迁移学习造成的灾难性遗忘问题。实验结果显示KDTM显著提升所有类别的分类性能，尤其是小样本类别。

1.3 论文组织结构

第一章，绪论。介绍了DGA检测的背景与意义，同时对该领域研究现状进行概述。

第二章，相关技术与理论。介绍了DGA域名生成技术、特征提取与表示学习、长短期记忆网络、多模态模型、预训练模型和注意力机制的概念。

第三章，问题分析与模型构建。分析了DGA检测优化方向，同时依据分析设计并构建本文的检测模型。

第四章，实验分析。介绍了模型实验设定，进行了参数分析与选取、消融实验和对比实验工作。

第五章，系统设计与实现。阐述了系统设计和系统实现的各个模块，并对相关代码文件进行解释说明。

第六章，展望与总结。概括了研究工作成果，并对未来研究方向进行展望。

第二章 相关理论与技术基础

2.1 DGA域名生成技术

2.1.1 基于域名生成算法（DGA）的僵尸网络

僵尸网络（Botnet）由大量被恶意软件感染的设备（如计算机、服务器、物联网设备等）组成，这些设备一旦被感染，便成为“僵尸节点”（通常称为Bot），并被攻击者（通常称为Botmaster）远程操控，执行各种恶意活动。作为网络空间最具破坏力的攻击载体之一，其通过分布式架构控制海量感染主机执行分布式拒绝服务攻击、数据窃取、勒索软件分发、发送垃圾邮件等恶意活动，已成为当前网络安全领域面临的最严峻的威胁之一^[7]。

在僵尸网络的运作中，C&C（Command and Control）服务器作为Botmaster与Bot之间的通信桥梁，起着至关重要的作用。Botmaster通过C&C服务器实现指令下发、恶意代码更新以及攻击协调等功能，而Bot节点则通过C&C服务器进行数据回传、指令接收以及恶意软件更新等操作。早期的僵尸网络多采用静态的C&C通信方式，通常使用固定的域名或IP地址作为C&C服务器的地址^[12]。然而，这种静态配置方式的隐蔽性较差，容易被安全防御系统识别并封锁。为了提高隐蔽性和抗检测能力，现代僵尸网络转而采用域名生成算法（DGA）实现动态域名解析。其工作机制如图2-1所示，这一过程通常由Botmaster按照预设规则批量生成伪随机域名集合，并在需要时从中随机选取部分域名进行注册并作为C&C服务器地址。Bot与Botmaster使用相同的DGA算法生成候选域名集合并持续进行连接尝试，直到某个域名成功解析，从而建立与C&C服务器的通信。

当前面向DGA域名的僵尸网络检测面临严峻的技术挑战。一方面，DGA通过动态生成大量域名，形成“域名洪流”，从而有效规避了传统基于黑名单的检测方法。以QakBot僵尸网络为例，其每小时生成约5000个域名，其中仅1%的域名实际解析到C&C服务器。这种冗余设计使得防御方即便封锁部分域名，攻击者仍能快速切换至新的可用域名，从而维持其控制网络的存活性^{[11][19][22]}，这种攻防博弈的极度不对称性显著增加了检测的难度^[34]。另一方面，DGA作为规避检测的工具，具备抗逆向性（结合时间戳和加密种子生成伪随机字符序列）、语义混淆性（生成类似自然语言的域名，模仿合法服务）以及极短的存活周期（域名的存活周期可缩短至数小时），这类高度的随机性和可变性，使得C&C服务器更加难以被识别、定位和追踪。




图2-1 域名生成算法运作机制图

2.1.2 DGA域名生成策略

DGA（Domain Generation Algorithm）域名生成算法的基本原理是通过确定性算法将种子（Seed，如时间戳、加密密钥或社交媒体热点）转换为动态域名序列，再拼接特定顶级域名（TLD，如.com、.cn、.co.uk）形成完整域名，从而实现僵尸网络与C&C服务器的隐蔽通信。种子作为攻击者与受控主机的共享密钥，决定域名的生成逻辑与周期性特征。

经过多年的发展，域名生成算法（DGAs）已形成了多种类型。根据其生成原理，可将其分为基于算术的、基于哈希的、基于词表的和基于排列的^[35]。基于算术的DGA，如Simda和Virut，是最常见的DGA，直接计算一系列ASCII码值来表示域名字符；基于哈希的DGA，如Bamital和Dyre，基于十六进制哈希生成域名；基于词表的DGA，如Matsnu和Suppobox，是最难检测的DGA。它们通过拼接词表中的两个或多个单词来生成域名；基于排列的DGA，如VolatileCedar，是最罕见的DGA。它们通过改变相同域名中字符的顺序来生成域名。

2.2 特征提取技术

2.2.1 基于统计的特征提取

基于统计的特征提取方法，即传统的特征工程方法，是一种经典的数据分析方法，其核心思想是通过计算数据的统计特性来构建特征表示。这种方法主要依赖于对数据分布的先验假设和经验知识，通过设计特定的统计指标来捕捉数据的关键特性。

在实现过程中，统计特征提取通常需要根据数据类型和问题需求设计合适的统计量。对于数值型数据，常用的统计特征包括均值、方差、偏度、峰度等分布特征；对于序列数据，则可能计算自相关函数、功率谱等时序特征。另外

还要对这些特征进行特征选择和优化。常用的方法包括基于信息增益的特征排序、基于相关性的特征筛选等，旨在去除冗余特征，提高特征集的判别效率。在实践中，这一步骤往往需要结合领域知识进行人工干预，以确保选取的特征具有实际安全意义。

统计特征提取方法具有计算效率高、可解释性强等优势，由于特征都是通过明确的数学公式计算得到，分析人员可以直观理解每个特征的含义。此外，这类方法通常计算复杂度较低，适合处理大规模数据。然而，其局限性在于难以自动捕捉数据中的复杂非线性关系，且对特征工程的质量高度依赖领域专家的经验；另一方面，攻击者也可以通过精心构造的对抗样本轻易绕过基于固定特征规则的检测系统。

2.2.2 基于深度学习的特征提取

基于深度学习的特征表示方法与传统的统计特征提取不同，它通过多层神经网络自动学习数据的分布式表示，实现了从原始数据到判别特征的端到端学习。

在技术实现层面，深度学习特征表示主要采用以下几种典型架构：卷积神经网络（CNN）擅长提取局部空间特征，适用于分析网络数据包、文件二进制等具有空间结构的数据；循环神经网络（RNN）及其变体（如LSTM、GRU）则更擅长处理时序依赖特征，在分析系统调用序列、网络流量等时序数据时表现出色；图神经网络（GNN）为分析网络拓扑、进程关系等图结构数据提供了新的技术路径。

深度特征表示的核心优势在于其强大的特征学习能力。通过多层次的非线性变换，深度学习模型能够自动发现数据中隐含的复杂模式，而无需依赖人工设计的特征规则。这种特性使得深度学习模型在面对新型、变种的安全威胁时表现出更好的泛化能力。此外，深度特征表示可以自然地融合多源异构的安全数据，为构建统一的安全检测框架提供了可能。然而这类方法存在模型可解释性差、训练数据需求大、计算资源消耗高等问题。当前研究正通过注意力机制、模型压缩等技术来应对这些挑战。

2.3 长短期记忆网络（LSTM）

长短期记忆网络（Long Short-Term Memory Network, LSTM）是一种特殊的循环神经网络（RNN）架构，旨在解决传统 RNN 在处理长序列数据时存在的梯度消失或梯度爆炸问题。其核心思想是通过引入精妙设计的门控机制来调节信息的流动，从而实现对长期依赖关系的有效建模。LSTM 单元的基本结构

包含三个关键门控单元：输入门（input gate）、遗忘门（forget gate）和输出门（output gate），以及一个细胞状态（cell state）作为网络的内存单元。

在门控机制的具体实现中，遗忘门通过可学习的参数矩阵动态决定历史信息的保留程度，输入门则控制新特征的更新强度，而输出门调节当前时刻的特征表达。这种架构的独特之处在于细胞状态通过恒定的误差传送带（constant error carousel）机制维持了梯度的稳定传播，从而保证了深层网络训练的有效性。

2.4 多模态模型

2.4.1 基本概念

多模态模型的理论基础源于对人类认知过程中多感官信息整合机制的仿生学模拟，其核心要义在于通过协同处理来自不同数据模态的特征表示来实现更全面、更鲁棒的模型推理能力。从计算理论的角度来看，多模态学习建立在模态间的互补性原则和一致性原则之上：前者认为不同模态提供的信息具有非重叠的判别性特征，后者强调不同模态对同一实体的描述应当在语义空间保持一致性。在数学形式上，给定一组来自 M 个不同模态的输入数据 $\{X_1, X_2, \dots, X_m\}$ ，多模态模型的目标是学习一个联合表示空间 $\Phi = \bigcup \phi(X_i)$ ，使得在该空间中既保留各模态的独有特征，又能捕捉模态间的潜在关联。现代多模态模型通常采用深度神经网络作为基础架构，通过模态特定的编码器将原始输入映射到统一的嵌入空间，这种设计既考虑了不同模态的数据特性差异，又为后续的特征融合提供了数学基础。

2.4.2 多模态特征融合

多模态特征融合的技术本质在于建立跨模态的特征交互机制，其理论框架可以表述为在共享表示空间中的特征张量运算问题。从实现方式上区分，特征融合主要包含早期融合（early fusion）、中期融合（intermediate fusion）和晚期融合（late fusion）三种范式，每种范式对应着不同的数学建模思路。早期融合直接在输入层将不同模态的特征向量进行拼接或加权组合，这种方法虽然计算效率高，但难以处理模态间的非线性交互。中期融合通过设计特定的融合算子（如张量连接、外积运算或注意力机制）在网络的中间层实现特征交互，其数学表达式可表示为 $\Phi = g(\Phi_1 \oplus \Phi_2 \oplus \dots \oplus \Phi_M)$ ，其中 $\oplus$ 表示融合算子， $g(\cdot)$ 为非线性变换函数。晚期融合则保持各模态的独立处理流程，仅在决策层进行结果集成，这种方法虽然保证了各模态的特征独立性，但可能丢失重要的跨模态关联信息。

2.5 预训练模型

预训练模型的技术理论基础植根于深度表示学习与迁移学习的交叉领域。在预训练模型中，通常先在大规模的无监督或有监督数据上进行预训练，学习到通用的特征表示。这些特征表示具有很强的泛化能力，能够捕捉到数据中的高级语义信息。然后，将预训练得到的模型参数作为初始化，在目标任务的小规模数据集上进行微调。

在实际应用中，有标签的数据往往是稀缺且昂贵的，而无标签的数据则非常丰富。所以预训练模型尝尝通过无监督学习算法，如自编码器（Autoencoder）、生成对抗网络（GAN）等，从大量的无标签数据中学习到数据的内在结构和特征。通过预训练的方式，模型可以利用在大规模数据上学习到的知识，更快地收敛到较好的性能，同时也能缓解目标任务数据不足的问题，这很好地契合了本文在不平衡场景下对域名关键特征表示提取的核心需求。

本文具体采用自编码器作为模型的一部分进行预训练。自编码器作为一种典型的无监督深度学习模型，通过数据驱动编码-解码机制来学习有效的特征表示。与普通的编码算法一样，自编码器算法的目的是将输入数据转换成一种新的表示方式，同时最大限度保留原始输入数据包含的信息。




图2-2 自编码器网络结构图

如图2-2所示，自编码器采用对称神经网络结构，由编码器 f_ϕ 和解码器 g_ψ 两部分组成，其中编码器将输入数据 $x \in \mathbb{R}^d$ 映射到低维潜在空间 $z \in \mathbb{R}^k (k \ll d)$ ，解码器则尝试从潜在表示重构原始输入。图中所示的编码器和解码器都是单层全连接神经网络。设 x 和 $\hat{x}$ 分别表示输入和输出， z 表示隐含层的输出结果， $\sigma(\cdot)$ 表示相应激活函数。原始输入 x 经过编码器得到隐含层输出 z 。则编码过程可表示为：

$$z = f_\phi(x) = \sigma(W_e x + b_e) \quad (2-1)$$

之后， z 经过解码器得到重构 $\hat{x}$ ，解码过程可表示为：

$$\hat{x} = g_{\psi}(z) = \sigma(W_d z + b_d) \quad (2-2)$$

在图2-2中，一般将隐含层输出 z 作为数据的特征，且其维度小于输入数据维度，所以称为 **bottleneck** 特征。模型通过最小化重构误差 $\mathcal{L}(x, \hat{x}) = \|x - g_{\psi}(f_{\phi}(x))\|_2^2$ 来优化参数，这种优化目标迫使潜在表示 z 必须保留输入数据的最关键信息。从数学本质上看，当采用线性激活函数且损失函数为均方误差时，自编码器等价于主成分分析（PCA），可以实现对原始数据的降维操作，找到可以代表原始信息的最重要的特征表示，但深度非线性架构使其能够学习更复杂的流形结构，因此它常被用于各个领域的特征提取，也适用于本文的DGA分类任务。

2.6 注意力机制

注意力机制的理论基础建立在动态权重分配的思想，它通过引入注意力权重实现对输入信息的加权聚合，从而提高模型对关键信息的关注能力。在深度学习模型中，注意力机制可以分为不同的类型，如点积注意力、缩放点积注意力、多头注意力等。点积注意力是最基本的形式，输入特征集 $\{x_i\}_{i=1}^n \in \mathbb{R}^d$ ，它首先将每个特征映射为查询（query）、键（key）和值（value）三个向量空间表示：

$$q_i = W_q x_i, \quad k_i = W_k x_i, \quad v_i = W_v x_i \quad (2-3)$$

其中 $W_q, W_k \in \mathbb{R}^{d_k \times d}$ ， $W_v \in \mathbb{R}^{d_v \times d}$ 为可学习的参数矩阵，分别实现查询、键和值的空间投影。注意力权重的计算基于内容的相似度度量，采用缩放点积形式：

$$\alpha_{ij} = \frac{\exp(\langle q_i, k_j \rangle / \sqrt{d_k})}{\sum_{l=1}^n \exp(\langle q_i, k_l \rangle / \sqrt{d_k})} \quad (2-4)$$

这种Softmax归一化确保权重满足概率分布特性 $\sum_j \alpha_{ij} = 1$ ，而缩放因 $\sqrt{d_k}$ 的引入用于控制点积幅值，防止梯度消失。最终的上下文感知特征表示为各位置值的加权和：

$$z_i = \sum_{j=1}^n \alpha_{ij} v_j \quad (2-5)$$

与传统的固定权重架构相比，注意力机制的核心优势在于其内容感知特性，每个输出位置的特征表示都根据输入序列的语义内容动态生成，这种自适应能力使其在建模长程依赖关系时表现出色。注意力机制在自然语言处理和计算机

视觉等领域都有着广泛的应用。本文选择在模型中加入注意力机制以帮助模型聚焦于域名中的关键表征信息，提高分类的准确性。

第三章 问题分析与模型构建

3.1 DGA 检测优化分析

3.1.1 DGA数据不平衡原因分析

现有的DGA检测器在整体水平和大型DGA家族上实现了较高的分类性能。然而，不同DGA家族之间存在严重的数据不平衡，大规模家族的样本数量可达数十万，而小规模家族仅有数百个甚至更少^[30]。造成DGA数据不平衡的原因主要有以下几点。

（1）DGA算法本身特性

一些小规模DGA家族本身在其生成期间产生的样本数量不足。同时一些新兴DGA家族由于出现时间短、生成速度慢、生成周期较长等原因样本数量很少。尽管AGD的生成速度远快于良性域名，但大多数每天生成的样本数量不到500个，有些甚至不到100个^[30]。然而有些DGA家族（如Conficker、Necurs）由于流行程度高，生成速度快等原因已被广泛用于恶意软件中，因此生成的恶意域名数量较多。

（2）研究具有偏向性

公开的DGA数据集通常基于已知的恶意软件样本或威胁情报报告，而这些样本可能更倾向于某些流行的DGA家族，对小规模DGA家族关注较少。同时，在长期的收集和研究过程中，一些DGA已积累了大量样本，有些DGA家族已被逆向分析以获取源代码并生成样本。

（3）数据标注困难

近年来新的DGA变体不断涌现，然而为小规模DGA家族和新兴DGA变体收集和标注足够的样本既费力又耗时^[35]。对于这些数据确定一个域名属于哪个DGA家族需要安全专家进行分析和验证，成本较高。

3.1.2 表征学习可行性探究

数据的不均衡分布会导致模型训练过程中出现类别偏好现象，具体表现为对多数类过拟合而对少数类欠学习，最终影响模型的整体泛化性能和检测精度。

现有关注数据不平衡问题的研究^[27-31]大都基于数据层面和算法层面。基于数据层面的解决方案主要采用重采样来平衡数据，如过采样。而基于算法层面的解决方案主要通过调整超参数来平衡各类别的权重，或者调整一些训练策略来平衡各类别的影响，如代价敏感学习。这些方法改善了模型在不平衡问题上的不足，然而本文通过对前沿模型检测结果的误分类样本进行深度剖析发现，经典的不平衡学习方法虽然能在一定程度上优化模型表现，却对某些特定DGA家

族的检测效果存在显著局限性。本文进一步通过混淆矩阵分析和特征可视化分析发现，这一缺陷的本质根源在于不同DGA家族生成的域名在语义表征空间存在高度重叠现象，模型难以从高度重叠的特征空间中提取有效的判别模式。具体而言，某些DGA算法生成的域名在字符熵值、n-gram分布等传统特征维度上表现出惊人的相似性（例如Necurs伪随机生成算法与Dridex深度学习生成模型的域名特征重叠度高达68%）。尽管这些类别的DGA样本存在语义混淆，但它们生成策略的显著差异性又暗示着在更细粒度的表征空间中应当存在可区分的特征维度。因此，如果能充分捕捉这些与生成机制强相关的语义特征，构建对DGA生成策略敏感的特征学习能力，深度挖掘域名生成过程中的时序依赖、概率分布模式等本质特征，将有望突破现有检测瓶颈，从而显著提升对语义混淆DGA家族的识别精度。

本文进一步通过对Emotet、Locky等典型DGA家族生成策略的深入分析，从长度策略、TLD选择、字符集偏好、排列组合模式及词典拼接等核心生成机制出发，揭示了这些机制在语义层面的特征模式（如表3-1所示）。基于这些生成机制，可以设计针对性的表征学习方案，为DGA表征学习的改进提供明确方向，从而提升DGA检测的准确性。例如，可以结合字符词元序列、word词元序列、n-gram序列、TLD特征、自然语言语素特征以及各类统计特征，构建能够全面覆盖不同DGA生成策略的语义特征学习方案。

表3-1 表征学习分析表

生成策略	说明	关键语义特征	表征学习方案
定长/变长策略	不同DGA采用不同的域名长度策略，如Qadars严格使用固定长度（12字符），而Locky v1支持5-24字符的动态生成	长度分布模式、长度编码差异	对于定长域名，引入长度编码特征，帮助区分长度相近但不同的域名
TLD选择策略	不同DGA有其偏好TLD集合，如Emotet偏向使用“.eu”，而Locky覆盖14种不同TLD（如“.yt”）	TLD集、周知/非周知TLD	对TLD词元序列进行语义学习
字符集偏好策略	不同DGA偏好不同字符集，如Cryptolocker仅使用字母，Rovnix混合使用字母与数	高熵值、低可读性、纯字母结构、数字字母混合结	对字符序列进行深度语义学习，结合字符集的统计特

	字，而Dyre使用SHA256哈希生成包含[0-9, A-F]的十六进制字符，但会额外添加一个[a-z]前缀破坏均匀分布	构、字符频率分布	征，识别出DGA特有的字符使用模式
排列组合类策略	通过字符置换或排列组合生成域名，如VolatileCedar通过字符置换生成初始域名排列组合。	Bigram 频率、字符位置相关性、相邻字符相关性	分析字符排列组合模式，识别域名生成中异常的Bigram分布及字符位置相关性
词典策略	通过拼接词典中的词汇生成域名，如Matsnu、Gozi	可读片段分布、元音比例	自然语言片段的识别

3.2 模型设计与实现

3.2.1 模型总体架构

基于对当前DGA检测面临的挑战及优化方法的系统分析优化分析结果，本文提出了PMAE-DGA方法。该方案充分关注DGA生成策略并提取出相应的多个维度的语义特征，然后基于多通道自编码器通过预训练机制实现多个通道语义特征融合，最后基于融合特征这种新的样本表征形式实现不平衡多分类学习，进而有效提升不平衡数据场景下的检测性能。如图3-1所示，该方案的整体架构包含三个关键阶段：

（1）阶段I-多通道语义特征提取

该阶段负责多维度DGA特征提取，实现对原始字符序列型DGA样本 $d \in \mathcal{D}_d$ 的预处理，并从顶级根域名、关键统计特征、随机构造词库和域名序列等多个关注DGA生成策略的维度，将 d 转换为多个维度的特征向量 $\mathbf{x}$ ；

（2）阶段II-预训练表征学习：

该阶段负责DGA语义表征学习与融合，利用多通道自编码器和跨通道注意力机制，通过联合学习的预训练方式提取DGA样本的内在结构信息和与目标任务相关的语义信息，从而实现对多通道语义特征的融合表征学习，即将 $\mathbf{x}$ 融合为 $\mathbf{h}$ ；

（3）阶段III-DGA不平衡多分类学习

该阶段负责在DGA语义表征充分学习的基础上，进行不平衡多分类学习，进一步提升DGA检测效果。首先将原始字符序列型的DGA数据集 $\mathcal{D}_d$ 转换为数

值型语义表示形式 $\mathcal{D}_h$ ，在此基础上，选择合适的分类算法和合适的不平衡学习方案（如Random Oversampling、SMOTE、Cost-Sensitive）对数据集 $\mathcal{D}_h$ 上进行再平衡检测模型构建。

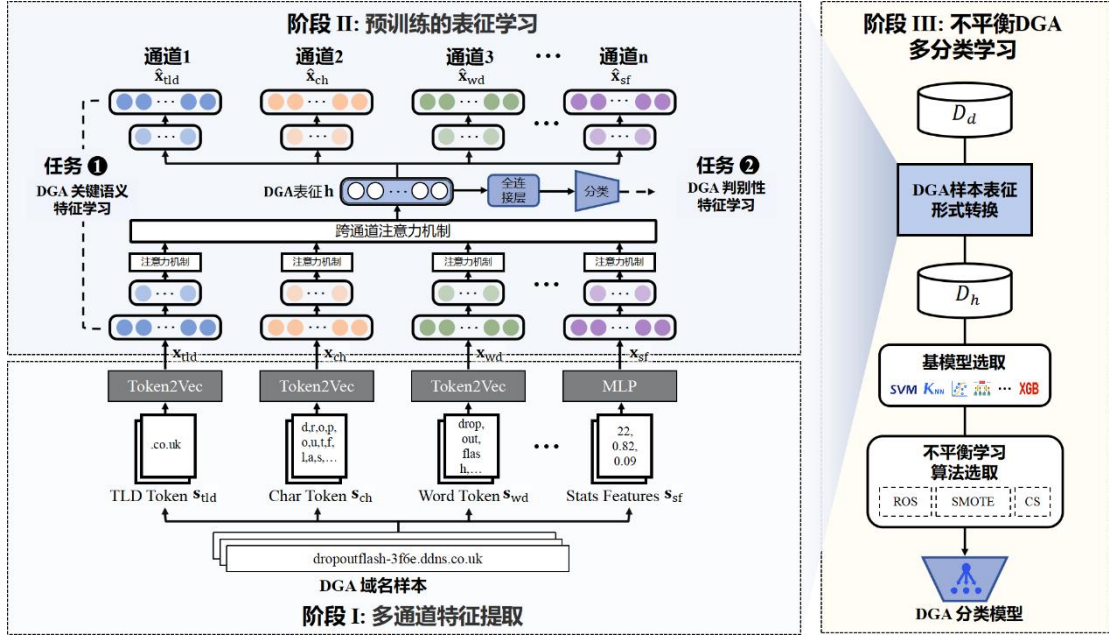


图3-1 PMAE-DGA模型整体架构图

3.2.2 多通道特征提取模块

3.2.2.1 多维度特征提取方案概览

本文突破传统单一维度特征提取模式的局限，构建了包含多尺度序列特征（字符级序列、词级序列、n-gram序列等）、顶级域名（TLD）信息，以及多维统计特征等在内的多维度多层次特征提取方案，为后续的多通道特征融合与表征学习建立基础。

本方案采用模块化设计思想，构建了一个可扩展的多通道特征提取架构，每个通道关注特定的域名语义信息的特征提取。具体实现中，本文构建了5个通道以提取以下5种特征，他们的通道名分别如下：TLD（tld）、Char（ch）、Word（wd）、BiGram（bi）、TriGram（tri）、Statistic Features（sf）。本文参考了系列论文构建多通道特征提取方案，各个通道在特征提取时关注的信息、通道的输入、特征处理方法、处理后的输出以及参考文献详细阐述如表3-2。

表3-2 特征通道相关信息表

通道名	侧重点	输入	处理方式	输出	参考文献
TLD	TLD偏好及其与长度编码的组合关系	s_{tld} : TLD词元及TLD与长度编码词元	TLD提取+长度编码+输入标记化+嵌入层 (50维) LSTM层 (64维) +全连接层 (64维)	64 维特征向量 x_{tld}	[9],[39],[40],[43]
Char	域名中的字符级序列模式	s_{ch} : 域名字符级序列	字符映射+输入标记化+嵌入层 (50维) LSTM层 (64维)+全连接层 (64维)	64 维特征向量 x_{ch}	[6],[20],[21],[22],[23],[26],[27],[29],[30],[34],[40],[43]
Word	域名中的英文单词等可读性片段的序列模式	s_{wd} : 域名高频单词序列	词典匹配+输入标记化+嵌入层 (50维) LSTM层 (64维)+全连接层 (64维)	64 维特征向量 x_{wd}	[41],[42],[43]
BiGram	域名中连续两个字符间的依赖关系和序列模式	s_{bi} : 域名2-gram片段序列	域名2-gram序列提取+输入标记化+嵌入层 (50维) LSTM层 (64维)+全连接层 (64维)	64 维特征向量 x_{bi}	[9],[10],[11],[12],[16],[17],[23],[32],[39],[43]
TriGram	域名中连续三个字符间的依赖关系和序列模式	s_{tri} : 域名3-gram片段序列	域名3-gram序列提取+输入标记化+嵌入层 (50维) LSTM层 (64维)+全连接层	64 维特征向量 x_{tri}	[9],[10],[11],[16],[17],[19],[41],[32],[39],[43]

			(64维)		
Statistic Features	域名的统计特征、自然语言特征、DGA 算法特性特征	s_{sf} : 各类统计特征、字符集特征、语素特征	统计特征 s_{sf} 提取 + 全连接层 (64 维)	64 维特征向量 x_{sf}	[9],[10],[11],[12],[19],[31],[32],[39],[40],[41]

每个通道在特征提取时主要包括两个环节：特征数据预处理、特征向量学习。特征数据预处理主要将域名从原始形式转换成特定特征通道的输入，特征向量学习主要接收各特征通道的输入，然后转换为充分提取其中语义信息的固定长度的特征向量。其中，TLD、Char、Word、BiGram、TriGram通道将域名 d 从原始的字符序列形式提取成tld字符、域名字符、word、2-gram、3-gram等词元序列形式 $s_{tld}, s_{ch}, s_{wd}, s_{bi}, s_{tri}$ ，然后再通过LSTM层等方式学习到每个特征通道的64维的嵌入向量表示形式；Statistic Features通道则是提取了多维度统计特征，然后经归一化处理后通过全连接层转为为64维的嵌入向量表示形式。各个通道提取和关注的特征列如表3-3所示。

表3-3 各通道关注的特征信息表

特征构成	特征名称	特征类型	相关描述
序列特征	s_{tld}	词元序列	TLD中的字符序列
	s_{ch}	词元序列	域名中的字符词元序列
	s_{wd}	词元序列	域名中的word词元序列
	s_{bi}	词元序列	域名中的2-gram词元序列
	s_{tri}	词元序列	域名中的3-gram词元序列
数值特征	domain_length	统计特征	域名长度
	ntld_length	统计特征	非顶级域名长度

	tld_length	统计特征	顶级域名长度
	entropy_letters	统计特征	英文字母的信息熵
	entropy_all_chars	统计特征	所有字符的信息熵
	contains_digit	字符特征	非顶级域名中是否含数字
	all_digits	字符特征	非顶级域名的字符是否全为数字
	all_letters	字符特征	非顶级域名的字符是否全为字母
	digit_ratio	字符特征	非顶级域名中数字字符的占比
	letter_ratio	字符特征	非顶级域名中英文字母的占比
	special_char_ratio	字符特征	非顶级域名中特殊字符的占比
	hex_char_ratio	字符特征	非顶级域名中十六进制字符的占比
	vowel_ratio	词法特征	非顶级域名中元音字母（包括a, e, i, o, u）的占比
	consonant_ratio	词法特征	非顶级域名中辅音字母的占比
	high_freq_ratio	词法特征	非顶级域名中英文高频字母（包括a,e,r,i,o,t,n）的占比
	low_freq_ratio	词法特征	非顶级域名中英文高频字母（包括w,k,v,x,z,j,q）的占比
	meaningful_word_ratio	词法特征	非顶级域名中出现的有意义的英文单词的字符数在非顶级域名总字符数的占比

3.2.2.2 多通道特征预处理

预处理的目的是针对不同特征通道关注的关键语义信息，将字符序列形式的域名样本转换为适合各通道学习的特定语义信息的原始状态，如字符级词元序列、词汇级词元序列、统计型数值等。

令长度为 n 域名 $d = c_1c_2...c_n, c_i \in \{a, b, ..., z, A, B, ..., Z, 0, 1, ..., 9, -, .\}$ 。本文参考由 Mozilla 和注册机构维护的公共后缀列表（PSL）^[35] 将域名划分为子域名和公共后缀（顶级域名，TLD），域名样本 d 的子域名和顶级域名分别表示为 d_{tld} ， d_{tld} 。各通道的特征预处理过程如下：

(1) **tld通道**: 首先, 将 d_{tld} 作为一个独立的词元进行处理; 其次, 将 d_{ntld} 的长度 l_{ntld} 分别除以 1、2、3 取整并转为长词元集合 $\mathcal{T}_{\text{len}} = \left\{ \left\lfloor \frac{l_{\text{ntld}}}{1} \right\rfloor, \left\lfloor \frac{l_{\text{ntld}}}{2} \right\rfloor, \left\lfloor \frac{l_{\text{ntld}}}{3} \right\rfloor \right\} \subseteq \mathbb{Z}^+$; 最后将TLD与各长度词元拼接形成新的词元字符序列 s_{tld} 。

(2) **char通道**: 将 d_{ntld} 按照字符顺序转换为词元字符序列 s_{ch} 。

(3) **Word通道**: 通过字典匹配机制, 提取域名 d 中的有效词汇级序列信息。具体处理过程为按序提取出域名中的英文单词及高频片段。本文依据常用英文单词表^[37], 构建通用英语词典; 通过统计方法提取出各类DGA样本中频繁出现的字符子串, 构建专用词汇级词元词库。

(4) **N-Gram通道**: 分别采用2元和3元连续子串分割策略, 提取域名中的局部模式特征, 最后得到2-gram和3-gram字符序列 $s_{\text{bi}}, s_{\text{tri}}$ 。

(5) **sf通道**: 对域名进行多维度统计特征提取, 并进行了Min-Max归一化, 得到统计特征向量 s_{sf} 。

3.2.2.3 多通道特征向量学习

多通道特征向量学习目标是将来自不同通道的多源异构原始特征统一映射为固定维度向量表示, 以便于后续特征融合。基于各通道数据特性差异, 本文分别设计针对序列特征和统计特征的特征向量学习。

本文针对Ch_TLD、Ch_Char、Ch_Word、Ch_BiGram、Ch_TriGram 5个序列型通道, 采用深度序列建模方法。针对域名样本 d 生成的特定字符序列数据 $s_c, c \in \{\text{tld}, \text{ch}, \text{wd}, \text{bi}, \text{tri}, \text{sf}\}$, 首先将离散词元序列转换为低维的稠密向量表示, Embedding层的输入是词元序列, 输出是每个token的嵌入向量:

$$\mathbf{e}_c = \text{Embedding}(s_c) \in \mathbb{R}^{d_e} \quad (3-1)$$

然后, 通过LSTM网络捕获序列依赖关系:

$$\mathbf{v}_c = \text{LSTM}(\mathbf{e}_c) \in \mathbb{R}^{d_v} \quad (3-2)$$

最后, 进行特征压缩, 将 $\mathbf{v}_c$ 经全连接层映射至统一特征空间:

$$\mathbf{x}_c = \text{ReLU}(\mathbf{W}_c^T \mathbf{v}_c + \mathbf{b}_c) \in \mathbb{R}^{d_x} \quad (3-3)$$

上述操作后原始词元序列型特征 $s_{\text{tld}}, s_{\text{ch}}, s_{\text{wd}}, s_{\text{bi}}, s_{\text{tri}}$ 被转换为固定长度为 d_x 的特征向量 $\mathbf{x}_{\text{tld}}, \mathbf{x}_{\text{ch}}, \mathbf{x}_{\text{wd}}, \mathbf{x}_{\text{bi}}, \mathbf{x}_{\text{tri}}$ 。

而本文针对sf通道的数值型统计特征，直接通过单层感知机进行维度标准化：

$$\mathbf{x}_{\text{sf}} = \text{ReLU}(\mathbf{W}_{\text{sf}}^T \mathbf{s}_{\text{sf}} + \mathbf{b}_{\text{sf}}) \in \mathbb{R}^{d_x} \quad (3-4)$$

3.2.3 预训练的代表学习模型

3.2.3.1 总体过程概述

表征学习的目标是针对多通道特征向量 $\mathbf{x} = [\mathbf{x}_{\text{tld}}; \mathbf{x}_{\text{ch}}; \mathbf{x}_{\text{wd}}; \mathbf{x}_{\text{bi}}; \mathbf{x}_{\text{tri}}; \mathbf{x}_{\text{sf}}]$ ，通过跨通道注意力机制和深度神经网络构建特征融合网络FS，实现多通道语义信息的融合，得到能充分体现DGA域名语义表征 $\mathbf{h}$ ：

$$\text{FS}: \mathbf{x} \rightarrow \mathbf{h} \in \mathbb{R}^{d_h} \quad (3-5)$$

在语义信息融合时，主要通过对两个任务的联合学习来驱动预训练过程：

(1) 引入多通道自编码器结构，通过基于融合特征 $\mathbf{h}$ 重构输入特征 $\mathbf{x}$ 的重构任务，增强 $\mathbf{h}$ 对域名自身的关键语义信息的保留与提取能力，该部分训练目标的重构损失表示为 $\mathcal{L}_{\text{recon}}$ ；(2) 通过DGA域名分类的多分类任务，增强 $\mathbf{h}$ 对DGA类别的区分性语义信息的提取能力，该部分训练目标的分类损失表示为 $\mathcal{L}_{\text{class}}$ 。最终的训练目标是加权损失的总和：

$$\mathcal{L}_{\text{total}} = \alpha \cdot \mathcal{L}_{\text{recon}} + (1 - \alpha) \cdot \mathcal{L}_{\text{class}} \quad (3-6)$$

α 为超参数，用于平衡重构损失和分类损失的权重。通过联合优化这两个损失函数，模型能够在保留域名自身语义信息的同时，增强与DGA域名分类任务相关的语义提取能力。

接下来，将对多通道DGA特征语义融合、DGA自身关键语义特征学习（重构任务）、DGA类间区分性特征学习（分类任务）的具体实现过程分别展开阐述。

3.2.3.2 多通道语义特征融合

特征融合网络FS在将通道的特征向量 $\mathbf{x}_c \in \mathbb{R}^{64}$ ($c \in \{\text{tld}, \text{ch}, \text{wd}, \text{bi}, \text{tri}, \text{sf}\}$) 融合为融合特征向量 $\mathbf{h}$ 的过程包括以下几个步骤：

首先，对单通道特征进行注意力加权，对于每个输入 $\mathbf{x}_c$ 通过注意力机制生成加权特征，其中注意力加权操作定义为：

$$\mathbf{h}_c = \text{Att}(\mathbf{x}_c) = \boldsymbol{\alpha}_c \odot \mathbf{x}_c, \quad \boldsymbol{\alpha}_c = \text{Softmax}(\mathbf{W}_c^T \mathbf{x}_c) \quad (3-7)$$

其中, $\mathbf{W}_c^T \in \mathbb{R}^{D \times 1}$ 为可学习注意力权重矩阵, $\odot$ 表示逐元素乘积, $\text{Softmax}(\cdot)$ 表示沿特征维度归一化。

然后, 将多个通道的加权特征进行concat拼接, 形成融合特征矩阵:

$$\mathbf{H}_m = [\mathbf{h}_{\text{tld}}^T \parallel \mathbf{h}_{\text{ch}}^T \parallel \mathbf{h}_{\text{wd}}^T \parallel \mathbf{h}_{\text{bi}}^T \parallel \mathbf{h}_{\text{tri}}^T \parallel \mathbf{h}_{\text{sf}}^T]^T \in \mathbb{R}^{6 \times d_h} \quad (3-8)$$

其次, 对拼接后的特征矩阵进行二次注意力加权得到:

$$\mathbf{H}_f = \text{Att}(\mathbf{H}_m) \in \mathbb{R}^{6 \times d_h} \quad (3-9)$$

最后, 通过一个多层感知机 (MLP) 投影到目标特征空间:

$$\mathbf{h} = \text{ReLU}(\mathbf{W}_f^T \mathbf{H}_f + \mathbf{b}_f) \in \mathbb{R}^{d_h} \quad (3-10)$$

3.2.3.3 DGA自身关键语义特征学习 (重构任务)

重构任务构建了堆叠式多通道自编码器网络 $f_\theta: \mathcal{X} \rightarrow \mathcal{H} \rightarrow \hat{\mathcal{X}}$, 其中 $\mathcal{X}$ 为原始特征空间, $\mathcal{H}$ 为融合特征的语义特征空间, $\hat{\mathcal{X}}$ 为重构特征空间。 f_θ 包含编码器 $\phi: \mathcal{X} \rightarrow \mathcal{H}$ 和解码器 $\psi: \mathcal{H} \rightarrow \hat{\mathcal{X}}$, 重构任务的训练目标是最小化重构损失 $\mathcal{L}_{\text{recon}}$, 即:

$$\min_{\phi, \psi} \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}} [\mathcal{L}_{\text{recon}}(\mathbf{x}, \psi(\phi(\mathbf{x})))] \quad (3-11)$$

具体地, 编码器 ϕ 处理过程为特征融合过程, 即 $\phi: \text{FSN}(\mathbf{x}) \rightarrow \mathbf{h}$, 实现将多个通道的原始特征向量融合为语义表征向量 $\mathbf{h}$ 。解码器 ψ 则基于融合特征向量 $\mathbf{h}$ 重构每个通道的原始特征向量 $\hat{\mathbf{x}} = \psi(\mathbf{h}) = [\hat{\mathbf{x}}_{\text{tld}}, \hat{\mathbf{x}}_{\text{ch}}, \hat{\mathbf{x}}_{\text{wd}}, \hat{\mathbf{x}}_{\text{bi}}, \hat{\mathbf{x}}_{\text{tri}}, \hat{\mathbf{x}}_{\text{sf}}]$ 。针对特定通道 $c \in \{\text{tld}, \text{ch}, \text{wd}, \text{bi}, \text{tri}, \text{sf}\}$, 其解码器 ψ_c 由两个全连接层 (Dense Layer) 组成。首先, 将融合表示 $\mathbf{h}$ 映射到中间特征空间 $\mathbf{z}_c$:

$$\mathbf{z}_c = \text{Dense}_1(\mathbf{h}) = \text{ReLU}(\mathbf{W}_c^1 \mathbf{h} + \mathbf{b}_c^1) \in \mathbb{R}^{32} \quad (3-12)$$

其中, $\mathbf{W}_c^1, \mathbf{b}_c^1$ 为特定通道第一层Dense层参数。然后, 将中间特征映射回原始输入空间, 得到重构输出 ψ_c :

$$\hat{\mathbf{x}}_c = \text{Dense}_2(\mathbf{z}_c) = \text{ReLU}(\mathbf{W}_c^2 \mathbf{z}_c + \mathbf{b}_c^2) \in \mathbb{R}^{64} \quad (3-13)$$

其中, $\mathbf{W}_c^2, \mathbf{b}_c^2$ 为特定通道第二层Dense层参数。最后, 计算通道 c 原始特征向量 $\mathbf{x}_c$ 与重构特征向量 $\hat{\mathbf{x}}_c$ 的均方误差:

$$\mathcal{L}_{\text{recon}}^c = \text{MSE}(\mathbf{x}_c, \hat{\mathbf{x}}_c) = \frac{1}{d_x} \sum_{i=1}^{d_x} (\mathbf{x}_c^i - \hat{\mathbf{x}}_c^i)^2 \quad (3-14)$$

同理可计算得到各个通道的重构损失 $\mathcal{L}_{\text{recon}}^{\text{tld}}, \mathcal{L}_{\text{recon}}^{\text{ch}}, \mathcal{L}_{\text{recon}}^{\text{wd}}, \mathcal{L}_{\text{recon}}^{\text{bi}}, \mathcal{L}_{\text{recon}}^{\text{tri}}, \mathcal{L}_{\text{recon}}^{\text{sf}}$, 最终将所有通道的重构损失加权求和, 得到总体重构损失函数 $\mathcal{L}_{\text{recon}}$:

$$\mathcal{L}_{\text{recon}} = \sum_c \mathcal{L}_{\text{recon}}^c, c \in \{\text{tld}, \text{ch}, \text{wd}, \text{bi}, \text{tri}, \text{sf}\} \quad (3-15)$$

3.2.3.4 DGA类间区分性特征学习 (分类任务)

分类任务在语义空间 $\mathcal{H}$ 上构建多分类模型 $g_\theta: \mathcal{H} \rightarrow \mathcal{Y}$, 其中 $\mathcal{Y}$ 为DGA家族类别空间。分类任务的训练目标是最小化分类损失 $\mathcal{L}_{\text{class}}$, 即:

$$\min_{\theta} \mathbb{E}_{(\mathbf{x}, y) \sim p_{\text{data}}} [\mathcal{L}_{\text{class}}(y, p_{\theta}(y | \mathbf{x}))] \quad (3-16)$$

具体地, 分类网络由两个全连接层 (Dense Layer) 组成。首先将融合表示 $\mathbf{h}$ 映射到中间特征空间 $\mathbf{z}$:

$$\mathbf{z} = \text{ReLU}(\mathbf{W}_z \mathbf{h} + \mathbf{b}_z) \in \mathbb{R}^{64} \quad (3-17)$$

其中, $\mathbf{W}_z, \mathbf{b}_z$ 为隐藏层参数。随后通过Softmax层输出概率分布:

$$\mathbf{y}_{\text{pred}} = \text{Softmax}(\mathbf{W}_o \mathbf{z} + \mathbf{b}_o) \in \mathbb{R}^{|\mathcal{C}|} \quad (3-18)$$

其中, $\mathbf{W}_o, \mathbf{b}_o$ 为输出层参数。分类任务采用交叉熵损失函数, 用于衡量模型预测的概率分布与真实标签的概率分布之间的差异。令 $\mathbf{y}_{\text{true}} \in \mathbb{R}^{|\mathcal{C}|}$ 为真实标签的独热编码向量, $\mathbf{y}_{\text{pred}} \in \mathbb{R}^{|\mathcal{C}|}$ 为模型预测的概率分布向量, 分损失函数为:

$$\mathcal{L}_{\text{class}} = \sum_{i=1}^{|\mathcal{C}|} y_{\text{true}}^i \log(y_{\text{pred}}^i) \quad (3-19)$$

3.2.4 DGA检测模型

DGA不平衡多分类学习主要涵盖三个关键环节: 样本表征转换、基模型的选择与构建以及不平衡学习方案的选择与构建。具体而言, 首先通过样本表征转换将原始序列型域名数据集 $\mathcal{D}_d$ 转换为语义特征向量数据集 $\mathcal{D}_h$; 其次, 在此

基础上选择适当的机器学习分类器构建DGA检测基模型；最后，通过选择合适的平衡分类算法优化检测效果。

3.2.4.1 数据集样本表征转换

在样本表征转换阶段，本文利用预训练的特征学习模型来提取DGA样本的关键特征。该模型已经完成多通道语义学习的训练，能够有效捕捉域名样本中的潜在模式。令原始域名数据集为 $\mathcal{D}_d = \{d_i\}_{i=1}^N$ ，其中 d_i 表示第 i 个域名字符序列。样本表征转换过程为：加载已训练好的多通道语义学习模型 Φ_θ ，遍历数据集 $\mathcal{D}_d$ 中的每个DGA样本，通过 Φ_θ 将原始序列空间映射到高维语义空间：

$$\Phi_\theta : \mathcal{D}_d \rightarrow \mathcal{D}_h = \{\mathbf{h}_i\}_{i=1}^N \quad (3-20)$$

其中 $\mathbf{h}_i = \Phi_\theta(d_i) \in \mathbb{R}^k$ 为 k -维语义特征向量。最后，将所有样本的数值向量保存，生成新的数据集 $\mathcal{D}_h$ 。

3.2.4.2 分类基模型选取与构建

本文采用多种机器学习分类器在数据集 $\mathcal{D}_h$ 上构建DGA检测的基模型，包括：XGBoost、支持向量机（SVM）、 k 近邻算法（KNN）、决策树（DT）、随机森林（RF）、朴素贝叶斯（NB）以及逻辑回归（LR）。然后基于Micro和Macro评估指标（Precision、Recall、F1-Score等），比较各分类器的检测性能，最后选择具有最佳性能的分类器作为最终基模型。

3.2.4.3 不平衡学习方案选择与构建

为进一步优化DGA检测模型在不平衡场景下的综合性能，基于选定的基模型，本文将再选取一种不平衡学习方案构建最终的DGA检测方案。本文将对以下经典的经典不平衡学习方案进行对比分析：

（1）ROS：通过随机增加少数类样本的数量来平衡数据集，具体做法为通过重复采样少数类使各类别样本比例接近1:1；

（2）SMOTE：通过生成新的少数类样本来平衡数据集，具体做法为在特征空间插值生成合成样本，使各类别样本比例接近1:1；

（3）Cost-Sensitive：通过修改分类器的损失函数，使其对少数类样本的分类错误给予更大的惩罚，具体做法为，针对特定的类别 c ，在交叉熵损失中引入类别权重 $w_c \propto \frac{1}{N_c}$ ，使其于该类别样本数 N_c 成反比。

通过综合比较不同不平衡学习方案的性能，本文将选择表现最佳的方案作为最终的DGA不平衡检测策略。

第四章 实验分析

4.1 实验设定

4.1.1 数据集介绍

为了获得更客观和全面的评估结果，本文在2个公开的主流数据集上进行了测试，分别是Bambenek咨询公司的OSINT DGA数据集^[37]和360 Netlab提供的DGA数据集^[38]，他们的DGA家族数量分布情况如图4-1和图4-2所示。

OSINT DGA数据集^[37]共包含37个DGA家族，现已被广泛应用于DGA检测研究中。该数据集的类别分布呈现出显著的不平衡性，部分类别的样本数量极为庞大，其中banjori、post和ramnit等类别的样本数量甚至超过 50,000。而banjori类别的样本数量最多，高达 45 万以上，是样本数量最少类别w32.virut的 7,668 倍。相比之下，许多类别的样本数量不足 200，如cryptowall（92 个样本）、bedep（177 个样本）和 hesperbot（190 个样本）。

360数据集^[38]由360网络安全实验室（360 Netlab）提供，这是一个广泛用于恶意域名检测和网络安全研究的开源数据集。360 Netlab作为知名的网络安全研究团队，长期致力于网络威胁情报的收集与分析，其提供的数据集具有高度的权威性和实用性。数据集中共有1,089,997 个样本，涵盖 40个类别，不同家族间样本数量差异大，存在显著的不平衡问题。其中，样本数量超过 10,000 的类别有 9 个，如banjori（452,277 个样本）、emotet（200,254 个样本）和 rovnix（179,998 个样本），这些类别的样本数量占据了数据集的绝大部分。而样本数量不足 1000 的类别达总类别一半。另外，该数据集中存在一些样本数量仅为个位数的DGA家族，它们的数量低至1到2个，如blackhole、mirai、xshellghost以及madmax。对这些类别进行分类没有参考价值，本文予以舍弃。

这两个数据集的头部类别（banjori）均占总量40%以上（360: 40.2%，OSINT: 42.7%），而尾部10%（将全部类别按样本量升序排列后，取最后10%的类别）的类别样本数占比不足0.1%（360: 0.08%，OSINT: 0.12%）。这种极不均衡的类别分布容易导致模型在训练过程中过度拟合样本数量较多的类别，而忽视样本数量较少的类别，从而影响少数类别的分类性能，因此这两个数据集都适合用于研究类别不平衡问题。




图4-1 OSINT数据集DGA家族数量分布情况条形图




图4-2 360数据集DGA家族数量分布情况条形图

4.1.2 实验环境

本文的实验在一台Linux服务器上进行，该服务器内核版本为 3.10.0 - 1160.119.1.el7.x86_64，GPU 为 NVIDIA GeForce RTX 3090，驱动版本 550.127.05，CUDA版本 12.4。实验采用Python语言开发，Python版本为 3.10.13，主要使用到的深度学习框架及相关库包括TensorFlow 2.10.0、Keras 2.10.0、NumPy 1.26.4、scikit-learn 1.3.0、imbalanced-learn 0.13.0。在训练表征学习模块时，训练轮次EPOCH设为 5，批量大小BATCH_SIZE为 32。优化器采用Adam，损失函数由分类交叉熵和自定义的自编码器重构损失组成，其 α 是分配不同通道输出的损失的关键参数。经实验最终在OSINT数据集和360数据集上分别设为0.8和0.4（详细分析在4.2给出）。

4.1.3 评价指标

在实验中本文采用 Macro-PRE, Macro-REC, Macro-F1, Micro-PRE, Micro-REC, Micro-F1, AVG 指标来衡量所提出的 PMAE-DGA 方法的有效性, 这些指标在多分类任务中具有不同的侧重点。TP 代表真正例, FP 代表假正例, FN 代表假负例。在本文的多分类任务中, 对于每个 DGA 家族, 该家族的样本为正样本, 其余的为负样本。准确率 (PRE) 和召回率 (REC) 是基础指标, 按照如下公式进行计算:

$$PRE = \frac{TP}{TP + FP} \quad (4-1)$$

$$REC = \frac{TP}{TP + FN} \quad (4-2)$$

Macro 系列指标对每个类别一视同仁, 能够有效反映模型在少数类别上的表现, 避免因类别不平衡导致的偏差, 从而在不平衡的多分类问题中更好地评估模型的整体效果。Macro-PRE (宏平均精确率) 和 Macro-REC (宏平均召回率) 分别计算每个类别的精确率和召回率, 然后对所有类别的结果取平均。而 Macro-F1 为 Macro-PRE 和 Macro-REC 的调和平均值, 能够更全面地反映模型在不同类别上的性能均衡情况。具体公式如下, 其中 n 表示类别数量, 和 PRE_i 分别表示第 REC_i 个类别的精确率和召回率:

$$Macro-PRE = \frac{1}{n} \sum_{i=1}^n PRE_i \quad (4-3)$$

$$Macro-REC = \frac{1}{n} \sum_{i=1}^n REC_i \quad (4-4)$$

$$Macro-F1 = \frac{2 \times Macro-PRE \times Macro-REC}{Macro-PRE + Macro-REC} \times 100\% \quad (4-5)$$

相比之下, Micro 系列指标则会更倾向于反映多数类的性能表现, 侧重于整体的分类效果。Micro-PRE (微平均精确率) 和 Micro-REC (微平均召回率) 将所有类别的真阳性、假阳性和假阴性汇总后计算全局的准确率 (PRE) 和召回率 (REC)。Micro-F1 为 Micro-PRE 和 Micro-REC 的调和平均值, 它从整体实例的角度综合了准确率和召回率。他们的计算公式如下:

$$Micro-PRE = \frac{\sum_{i=1}^n TP_i}{\sum_{i=1}^n TP_i + \sum_{i=1}^n FP_i} \quad (4-6)$$

$$\text{Micro-REC} = \frac{\sum_{i=1}^n \text{TP}_i}{\sum_{i=1}^n \text{TP}_i + \sum_{i=1}^n \text{FN}_i} \quad (4-7)$$

$$\text{Micro-F1} = \frac{2 \times \text{Micro-PRE} \times \text{Micro-REC}}{\text{Micro-PRE} + \text{Micro-REC}} \times 100\% \quad (4-8)$$

AVG是Micro-F1和Macro-F1的算术平均，用于综合评估模型在全局和类别平衡两方面的表现。它根据以下公式得出：

$$\text{AVG} = \frac{\text{Micro-F1} + \text{Macro-F1}}{2} \times 100\% \quad (4-9)$$

4.2 参数分析与选取

4.2.1 权重分析

模型中损失由AE（自动编码器）与Softmax两部分损失构成，权重主要通过关键参数 α 来确定和分配，Softmax损失的权重（Softmax loss_weight）直接采用 α 值，而AE损失的权重（AE loss_weight）值则为 $1 - \alpha$ 。

当 α 较小时，AE loss_weight值较大，模型会更注重AE部分的训练，从而更倾向于学习数据的重构特征；而当 α 较大时，AE loss_weight较小，模型会更注重Softmax部分的训练，从而更倾向于学习分类任务的特征。

α 参数值直接决定了模型训练中Softmax和AE两部分损失的相对权重，进而对模型的训练过程和最终性能产生重要影响。

为选取最佳权重，本文选择F1系列指标作为主要评估依据，因为它能够综合反映模型的精度和召回率，从而提供更为全面的性能评估。




图4-3 各权重下的模型表现折线图

图4-3展示了在不同权重下不同数据集上的micro-F1和macro-F1值，为方便直观展示和叙述AE效果，本文采用AE自编码器的损失权重AE loss_weight作为横坐标。

Macro-F1对于不平衡场景下多分类任务中模型性能的均衡评估至关重要，如图4-3所示，当完全禁用AE模块（ $w=0$ ）时，模型在OSINT和360数据集上的Macro-F1值分别低至69.34%和67.73%，较最优权重下的性能存在显著差异，这一结果充分证明了AE在改善类别预测均衡性上的作用。

在OSINT数据集上，随着AE权重值的增加，Macro-F1呈现先升后降的趋势，在AE loss_weight=0.2时达到峰值71.39%，而Micro-F1值数据变化趋势较平缓，各权重下数据差异不大。在AE loss_weight为0.2时，OSINT数据集的Micro-F1值为96.39%，仅比峰值低0.23%，能保持在较高水平。从OSINT数据集的数据总体趋势来看，两项指标在AE权重为0.2时上达到了最佳平衡。

而对于360数据集，模型表现出更强的AE依赖性。当AE loss_weight=0.6时，Macro-F1达到72.36%，同时Micro-F1维持在99.07%的高水平，二者均处于峰值。这种差异可能源于360数据集更高的类别不平衡度，使得AE的特征重建任务对少数类别的识别更为关键。

综上，本文最终在OSNIT数据集和360数据集上分别选取最优AE权重：0.2和0.6，也即关键参数 α 分别设为0.8和0.4。这一选择确保了模型能在不同数据集和评估指标上均能达到较优的结果。

4.2.2 特征通道选择

本文中Ch_TLD代指tld组合特征通道；Ch_Char代指域名字符通道；Ch_Word代指高频Token通道；Ch_BiGram代指2-Gram序列通道；Ch_TriGram代指3-Gram序列通道；Ch_SF代指统计特征通。

如表4-1所示，在OSINT数据集上，Ch_TLD展现出最均衡的性能表现，其Micro-F1达到96.55%，同时Macro-F1为70.91%，较最低性能通道Ch_Word提升6.4%。Ch_BiGram展现出突出的对少数类别的识别能力，在保持优异Micro-F1（96.72%）的同时，实现了最高的Macro-F1召回率（72.03%）。在360数据集上，Ch_SF和Ch_BiGram通道表现出显著的互补优势。Ch_SF取得了最优的Micro-F1（99.07%），而Ch_BiGram则在Macro指标上表现最为稳定。Ch_Char的Micro和Macro指标表现处于中游位置，但其跨数据集的稳定性最佳（Micro-F1标准差 <0.0015 ），且在两类数据集的Macro-F1差异最小，展现出卓越的泛化能力。

综上，本文最终选择Ch_TLD、Ch_SF、Ch_BiGram及Ch_Char四个特征通道作为表征学习的核心输入，为后续的深度表征学习奠定坚实基础。

表4-1 多通道特征提取模块中各单通道的性能表现

数据集	通道名	Micro系列指标			Macro系列指标		
		PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)
OSINT DGA 数据集	Ch_TLD	96.68	96.71	96.55	79.55	69.72	70.91
	Ch_Char	96.56	96.59	96.43	76.84	70.44	70.52
	Ch_Word	94.74	94.77	94.60	74.83	66.44	66.67
	Ch_BiGram	96.79	96.84	96.72	77.06	72.03	71.75
	Ch_TriGram	96.62	96.66	96.50	79.13	64.60	68.35
	Ch_SF	96.54	96.60	96.45	76.83	68.43	70.00
360 DGA 数据集	Ch_TLD	98.01	98.15	98.02	77.95	65.10	68.05
	Ch_Char	97.99	98.17	98.04	78.45	65.29	68.06
	Ch_Word	97.93	98.10	97.98	74.40	64.57	67.35
	Ch_BiGram	99.06	99.10	99.04	76.21	70.44	70.77
	Ch_TriGram	97.79	97.94	97.84	76.22	66.70	68.85
	Ch_SF	99.05	99.16	99.07	74.82	70.67	70.97

4.2.3 基分类器选择

将原始数据集经表征学习模型转化后，本文得到了数值型语义表示形式的数据集360 DGA和OSINT DGA。为选取最佳的分类器作为本文模型的检测器基模型，本文对一系列分类器进行了实验。表4-2展示了SVM、KNN、Naive bayes、XGBoost、Random forest、Decision tree和Logistic分类器在这两个数据集上的Micro和Macro指标表现。在360 DGA数据集上，各分类器的Micro指标表现都较为出色，差异较小。而Macro指标中，XGBoost的表现相对突出，Macro - F1值表现最佳，达到75.26%。在OSINT DGA数据集上，Micro系列指标方面，XGBoost与SVM、Random forest分类器表现较好；Macro指标上，XGBoost和Random forest的Macro系列指标较为接近且都处于较高水平。

综合来看，XGBoost是一个更优的选择。在数据集360 DGA和OSINT DGA上，它的Micro系列指标都表现出色。而Macro系列指标作为关键指标表现更加突出，其中Macro - F1值在两个数据集上都处于峰值。

表4-2 不同分类器性能表现

数据集	分类器	Micro系列指标			Macro系列指标		
		PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)
OSINT DGA 数据集	Naive bayes	96.71	88.07	89.80	58.34	75.54	58.11
	Logistic	97.11	97.23	97.09	77.87	70.10	72.16
	SVM	97.29	97.31	97.17	82.29	72.30	73.39
	KNN	96.96	97.10	96.97	75.87	70.21	71.72
	Decision tree	95.79	95.77	95.77	70.09	70.53	70.18
	Random forest	97.26	97.31	97.19	83.10	72.31	74.32
	XGBoost	97.08	97.18	97.06	82.15	72.07	74.47
360 DGA 数据集	Naive Bayes	98.93	91.11	93.05	62.47	69.60	57.68
	Logistic	99.16	99.25	99.18	79.83	71.39	72.71
	SVM	99.15	99.26	99.18	75.85	71.12	72.00
	KNN	99.13	99.20	99.14	76.40	72.10	73.23
	Decision tree	98.88	98.87	98.87	72.33	72.59	72.37
	Random forest	99.20	99.25	99.20	79.28	73.34	74.75
	XGBoost	99.17	99.23	99.18	79.44	73.51	75.26

4.2.4 不平衡优化算法选择

为进一步优化DGA检测模型在不平衡场景下的综合性能，本文构建了不平衡优化算法评估框架。实验采用经表征学习模型提取语义特征后的数值型数据集和XGBoost分类器构建检测基线模型（PMAE+XGBoost），并在此基线模型基础上使用三种典型的不平衡学习方案上进行了分析，它们分别是随机过采样（ROS）、SMOTE和代价敏感学习（Cost-Sensitive）。

如表4-3实验结果显示，在OSINT数据集上，CS方案展现出最优的综合性能，与其他方案相比其Micro-F1（97.18%）略优于基线模型（97.06%），同时显著提升了Macro-F1至75.05%。

在360数据集上，Cost-Sensitive方案同样表现出卓越的稳定性，其Micro-F1（99.14%）表现与基线相当，同时Macro-F1（76.09%）也有一定提升。相比之下，SMOTE方案整体性能略低于基线模型，并未改善基线模型表现。而ROS方案表现不佳，导致基线模型整体性能下降严重，这一现象印证了简单过采样在高不平衡场景下的局限性。

基于实验结果分析，Cost-Sensitive是本文检测模型最合适的不平衡优化算法，本文最终将基于Cost-Sensitive构建检测模型。

表4-3 不同不平衡优化算法对模型的改善效果

数据集	分类器	Micro系列指标			Macro系列指标		
		PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)
OSINT DGA 数据集	Baseline基线模型	97.08	97.18	97.06	82.15	72.07	74.47
	+ ROS	80.62	66.40	71.84	27.23	50.36	25.90
	+ SMOTE	96.77	96.30	96.49	71.06	74.51	72.18
	+ Cost-Sensitive	97.18	97.18	97.18	76.88	75.19	75.05
360 DGA 数据集	Baseline基线模型	99.17	99.23	99.18	79.44	73.51	75.26
	+ ROS	92.41	80.81	85.00	26.48	40.42	24.20
	+ SMOTE	99.01	98.78	98.88	71.47	74.39	72.47
	+ Cost-Sensitive	99.14	99.14	99.14	76.86	78.33	76.09

4.3 消融实验

4.3.1 学习模块增量验证实验

本文采用消融实验系统地验证了各模块对模型性能的贡献。实验从基础模型出发，逐步引入关键改进模块，形成四个具有明确递进关系的实验组别。

实验的基线模型（Baseline）采用基于Ch_Char单通道特征（域名字符序列）的LSTM架构，基线模型仅利用域名的原始字符序列信息，通过LSTM（长短期记忆网络）捕捉时序模式，为后续实验提供性能比较的基准。在基线模型的基础上，特征增强实验组（Multichannel Feature）扩展了特征表示空间，使用多通道特征（Ch_TLD、Ch_SF、Ch_BiGram、Ch_Char）作为输入，在保留原始字符序列特征的同时，引入了包括词法特征、统计特征和结构特征在内的多维度特征。这些特征共同构成更丰富的特征表示，使模型能够从多个角度理解域名特性。预训练优化实验组（Pretrained MAE）在特征增强的基础上引入了基于多

通道自编码器（MAE）的预训练机制。该模块对每个通道特征进行注意力加权并引入多通道自编码器结构，通过重构任务有效捕捉域名中更深层次的语义模式。同时本文使用该模块对原始数据集进行样本表征转换。最终的不平衡优化实验组（Imbalanced Optimization）在Pretrained MAE学习到语义特征基础上，针对实际场景中的类别不平衡问题，设计了基于XGBoost分类器和Cost-Sensitive算法的不平衡优化模块以进一步改善对少数类的检测效果。

表4-4 OSINT数据集——学习模块增量验证实验结果

DGA家族类别	Baseline (Ch_Char+LSTM)			+ Multichannel Feature			+ Pretrained MAE			+ Imbalanced Optimization		
	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)
Geodo	56.59	100.0	72.28	57.22	100.0	72.79	56.91	100.0	72.54	58.55	98.26	73.38
Beebone	94.74	47.37	63.16	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0
Murofet	85.79	85.71	85.75	83.01	88.59	85.71	81.66	90.62	85.90	86.97	88.57	87.76
Pykspa	67.68	24.28	35.73	77.21	38.04	50.97	80.50	46.38	58.85	80.43	77.66	79.02
Padcrypt	97.92	63.51	77.05	90.67	91.89	91.28	90.28	87.84	89.04	88.89	96.00	92.31
Ramnit	86.61	90.19	88.36	86.42	91.89	89.07	87.59	90.57	89.06	89.88	93.67	91.74
Volatile	100.0	39.29	56.41	81.82	80.36	81.08	76.92	89.29	82.64	100.0	100.0	100.0
Ranbyus	85.99	91.74	88.77	93.46	87.78	90.53	92.46	90.41	91.42	93.75	95.18	94.46
Qakbot	69.27	75.30	72.16	71.41	74.46	72.90	71.67	74.30	72.96	72.80	76.01	74.37
Simda	99.10	99.98	99.54	97.14	99.94	98.52	98.43	99.79	99.11	99.81	100.0	99.91
Ramdo	74.03	64.77	69.09	82.83	93.18	87.70	90.24	84.09	87.06	95.51	98.84	97.14
Suppobox	85.39	99.78	92.03	90.62	93.00	91.79	90.87	93.65	92.24	96.22	99.35	97.76
Locky	100.0	11.76	21.05	97.10	30.32	46.21	82.56	32.13	46.25	70.65	31.40	43.48
Tempedreve	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	5.26	2.44	3.33
Qadars	94.51	82.58	88.14	97.75	87.88	92.55	78.07	81.82	79.90	96.64	93.50	95.04
Symmi	100.0	100.0	100.0	99.89	100.0	99.94	99.89	100.0	99.94	99.77	100.0	99.88
Banjori	99.98	99.99	99.98	99.98	99.98	99.98	99.98	99.99	99.99	99.99	99.99	99.99
Tinba	88.42	98.91	93.37	90.18	99.08	94.42	90.55	98.27	94.25	95.16	99.48	97.28
Hesperbot	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	15.38	5.26	7.84
Fobber	31.43	32.84	32.12	41.51	32.84	36.67	43.14	32.84	37.29	48.84	37.50	42.42
Dyre	97.65	100.0	98.81	100.0	100.0	100.0	99.20	100.0	99.60	100.0	100.0	100.0
Cryptowall	0.0	0.0	0.0	0.0	0.0	0.0	50.0	36.0	41.86	28.0	38.89	32.56
Corebot	76.40	100.0	86.62	100.0	98.53	99.26	100.0	98.53	99.26	100.0	98.21	99.10
Proslkefan	0.0	0.0	0.0	66.67	24.49	35.82	76.92	20.41	32.26	52.94	36.0	42.86
Bedep	100.0	14.71	25.64	0.0	0.0	0.0	0.0	0.0	0.0	8.33	2.86	4.26
Matsnu	77.01	95.71	85.35	89.19	94.29	91.67	100.0	90.0	94.74	100.0	91.86	95.76
Post	100.0	99.82	99.91	100.0	99.99	100.0	99.99	99.99	99.99	100.0	99.99	100.0
Necurs	95.33	86.25	90.56	95.37	87.30	91.16	95.63	87.17	91.20	97.22	86.20	91.38
Pushdo	90.91	84.27	87.46	81.71	80.34	81.02	84.66	83.71	84.18	89.62	94.80	92.13
Cryptolocker	0.0	0.0	0.0	60.0	28.65	38.78	67.21	23.03	34.31	35.37	34.12	34.73
Dircrypt	0.0	0.0	0.0	0.0	0.0	0.0	47.37	5.73	10.23	17.78	15.69	16.67
Shifu	88.45	97.14	92.59	95.94	91.82	93.83	94.79	96.73	95.75	96.01	99.21	97.58
Bamital	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0
Kraken	98.86	76.55	86.28	98.87	77.26	86.74	96.71	78.05	86.39	87.47	86.76	87.11
Nymaim	37.50	6.38	10.91	47.06	8.51	14.41	72.22	13.83	23.21	71.43	21.51	33.06
Shiotob	95.89	93.99	94.93	97.39	92.00	94.62	94.22	87.19	90.57	97.04	91.23	94.05
W32.Virut	61.90	76.47	68.42	60.0	52.94	56.25	58.62	100.0	73.91	68.75	91.67	78.57
Micro-avg	96.09	96.28	96.05	96.42	96.54	96.38	96.50	96.53	96.39	97.17	97.18	97.12
Macro-avg	71.28	63.22	63.85	73.79	68.25	69.34	79.71	70.68	71.39	76.88	75.19	75.05
Micro +	0.0	0.0	0.0	+0.33	+0.26	+0.33	+0.41	+0.25	+0.34	+1.08	+0.90	+1.07
Macro +	0.0	0.0	0.0	+2.51	+5.03	+5.49	+8.43	+7.46	+7.54	+5.60	+11.97	+11.20

表4-5 360数据集——学习模块增量验证实验结果

DGA家族类别	Baseline (Ch_Char+LSTM)			+ Multichannel Feature			+ Pretrained MAE			+ Imbalanced Optimization		
	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)
bamital	100.0	41.18	58.33	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0
banjori	99.99	100.0	99.99	98.93	99.93	99.43	99.98	100.0	99.99	100.0	100.0	100.0
chinad	97.58	79.70	87.74	100.0	99.50	99.75	100.0	100.0	100.0	98.51	99.50	99.00
conficker	7.69	9.71	8.58	68.89	30.10	41.89	96.67	28.16	43.61	45.83	33.33	38.60
cryptolocker	80.77	21.21	33.60	71.58	34.34	46.42	79.80	39.90	53.20	51.58	57.00	54.16
dircrypt	0.0	0.0	0.0	33.33	1.11	2.15	0.0	0.0	0.0	46.67	7.53	12.96
dyre	95.15	100.0	97.52	100.0	100.0	100.0	100.0	100.0	100.0	100.0	99.50	99.75
emotet	99.98	100.0	99.99	99.99	100.0	100.0	99.99	100.0	100.0	99.99	100.0	99.99
fobber_v1	0.0	0.0	0.0	50.0	1.82	3.51	33.96	98.18	50.47	36.09	81.36	50.0

fobber_v2	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	18.35	85.00	30.18
gameover	99.96	99.13	99.54	99.71	99.17	99.44	100.0	99.04	99.52	99.87	99.46	99.67
gspy	30.51	100.0	46.75	85.71	100.0	92.31	100.0	100.0	100.0	100.0	100.0	100.0
locky	64.00	29.36	40.25	79.83	43.58	56.38	89.80	40.37	55.70	68.06	58.04	62.65
matsnu	93.83	93.83	93.83	98.06	93.83	95.90	100.0	93.83	96.82	95.63	96.15	95.89
murofet	80.55	76.96	78.71	87.61	84.22	85.88	82.45	90.03	86.07	87.90	86.75	87.32
necurs	92.45	84.50	88.30	94.90	86.80	90.67	90.16	90.38	90.27	96.81	85.16	90.61
nymaim	0.0	0.0	0.0	16.67	1.28	2.38	0.0	0.0	0.0	40.82	24.69	30.77
padcrypt	100.0	20.59	34.15	85.71	88.24	86.96	97.06	97.06	97.06	83.78	93.94	88.57
proslkefan	0.0	0.0	0.0	0.0	0.0	0.0	50.0	11.76	19.05	30.00	30.00	30.00
pykspa_v1	99.45	99.21	99.33	90.22	92.65	91.42	99.53	99.90	99.71	99.71	99.64	99.68
pykspa_v2_fake	29.80	52.05	37.91	31.82	28.77	30.22	30.94	47.26	37.40	40.61	58.13	47.81
pykspa_v2_real	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	15.00	7.50	10.00
qadars	99.72	97.53	98.61	99.72	96.98	98.33	100.0	97.53	98.75	99.15	97.50	98.32
ramnit	79.67	90.91	84.92	79.81	72.27	75.85	83.65	87.68	85.62	85.33	85.08	85.21
ranbyus	85.45	82.14	83.76	90.04	82.54	86.13	94.66	75.60	84.06	90.34	80.14	84.94
rovnix	99.94	99.83	99.89	99.85	99.83	99.84	99.95	99.81	99.88	99.99	99.78	99.88
shifu	81.29	98.05	88.89	91.53	73.54	81.55	95.52	99.61	97.52	96.94	99.22	98.07
simda	99.50	99.92	99.71	92.26	89.60	90.91	99.68	99.96	99.82	99.71	99.92	99.82
suppobox	96.76	93.72	95.22	89.59	91.84	90.70	98.59	87.66	92.80	95.91	97.91	96.90
symmi	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0
tempedreve	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	16.67	14.63	15.58
tinba	97.69	99.85	98.76	97.43	99.00	98.21	97.78	99.96	98.86	98.80	99.70	99.25
tofsee	0.0	0.0	0.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0
vawtrak	65.79	47.17	54.95	73.58	73.58	73.58	65.22	84.91	73.77	73.08	98.28	83.82
vidro	66.67	11.76	20.00	100.0	5.88	11.11	100.0	29.41	45.45	56.25	45.00	50.00
virut	99.26	93.94	96.53	99.21	100.0	99.60	99.40	100.0	99.70	99.50	99.95	99.72
Micro avg	98.81	98.93	98.83	97.95	98.15	98.01	99.06	99.15	99.07	99.21	99.14	99.15
Macro avg	65.10	58.95	59.05	75.17	65.84	67.51	77.35	72.17	72.36	76.86	78.33	76.09
Micro +	0.0	0.0	0.0	-0.86	-0.78	-0.82	+0.25	+0.22	+0.24	+0.40	+0.21	+0.32
Macro +	0.0	0.0	0.0	+10.07	+6.89	+8.46	+12.25	+13.22	+13.31	+11.76	+19.38	+17.04

表4-4和表4-5展示了不同数据集上消融实验的结果，从这两个数据集的消融实验数据来看，在OSINT数据集中，相较于基线模型（Ch_Char+LSTM），Multichannel Feature模块在一定程度上改善了模型对部分类别样本的处理能力，Micro系列指标和Macro系列指标有所提升，部分少数类如Beebone的检测效果提升显著。在此基础上加入Pretrained MAE模块后，微观平均和宏观平均指标均有大幅提升，尤其是Macro-F1值进一步提升0.0754，其中Pykspa等家族的F1值提升超过20个百分点，验证了MAE的有效性。最终引入Imbalanced Optimizatio模块后，宏观F1值达到75.05%，较基线提升11.20%。

在360数据集上改进趋势更为明显。Multichannel Feature模块使宏观F1值提升8.46%，其中conficker等难分类家族的F1值提升超过30%。Pretrained MAE模块带来更显著的改进，宏观F1值提升13.31%。最终模型在引入Imbalanced Optimizatio模块后，宏观F1值达到76.09%，较基线提升17.04%，且vawtrak等家族的召回率提升超过13个百分点。

值得注意的是，各模块的引入打破了许多少数类、难分类的0检测率状态，实现了从无到有的突破。如在OSINT数据集中，样本数仅204的Tempedreve家族，从Imbalanced Optimizatio模块中获得了3.33%的F1提升（从0→0.0333），样本数190的Hesperbot家族F1从0提升至7.84%；在360数据集上，样本量仅20的tofsee家族在引入Multichannel Feature后实现F1从0到1.0的突破，而样本数297的fobber_v1家族通过Pretrained MAE模块F1值达到50.47%（基线为0）。另外，最

终的PMAE在两个数据集的Micro-F1相较于基线都略有增幅，说明PMAE在提升少数类性能的同时未牺牲整体检测效果。

这些实验结果一致表明，在OSINT和360两个数据集上，随着PMAE模型的不同核心模块（Multichannel Feature、Pretrained MAE、Imbalanced Optimization）的逐步引入，模型性能呈现出明显的提升趋势。PMAE通过这三个核心模块的协同作用，有效提升了恶意域名检测的整体性能。

4.3.2 预训练的表征学习模块增益效果分析

为了进一步探究PMAE预训练表征学习的增益效果，本文还针对不同特征通道下的Pretrained MAE性能表现展开了对比分析，实验数据由表4-6给出（Multichannel Feature缩写为MF、Pretrained MAE缩写为PMAE；Ch_TLD代指tld组合特征通道；Ch_Char代指域名字符通道；Ch_BiGram代指2-Gram序列通道；Ch_SF代指统计特征通；ALL代指最终融合通道）。如图4-4和图4-5显示，Pretrained MAE模块在不同特征通道不同数据集上Macro-F1指标均展现出显著的性能提升，Micro-F1指标波动不大，略有增长。以OSINT数据集为例，在Ch_Char通道中，Pretrained MAE将Macro-F1从Multichannel Feature的63.85%提升至70.52%；而在Ch_SF通道中，不仅Micro-F1从95.31%提升至96.45%，Macro-F1也实现了9.3%的相对提升。其余两个单通道上Macro-F1指标也都实现了超7%的相对提升。在360数据集上，相较Multichannel Feature，Ch_SF通道的Micro-F1从98.89%提升至99.07%，Macro-F1从64.79%提升至70.97%，相对提升达到9.5%。Pretrained MAE对基础域名字符特征的表示学习效果尤为突出，在Ch_Char上，Macro-F1的提升幅度达到15%（59.05%→68.06%）。当整合所有通道（All）时，相较Multichannel Feature，两个数据集的Macro-F1均获得一定的相对提升。实验结果共同表明，Pretrained MAE的预训练表征学习能够有效适应不同特征通道的特性并深度挖掘域名的本质特征，在保持整体检测率优势的同时，显著提升对难分类和稀有家族的识别能力。

表4-6 预训练的表征学习模块相对多通道特征模块的增益效果

数据集	通道名	Multichannel Feature						Pretrained MAE					
		Micro			Macro			Micro			Macro		
		PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)
OSINT	Ch_Char	96.09	96.28	96.05	71.28	63.22	63.85	96.56	96.59	96.43	76.84	70.44	70.52
	Ch_SF	95.65	95.55	95.31	73.57	63.84	64.07	96.54	96.60	96.45	76.83	68.43	70.00
	Ch_TLD	96.39	96.43	96.24	75.18	65.70	66.18	96.68	96.71	96.55	79.55	69.72	70.91
	Ch_BiGram	96.22	96.34	96.16	70.47	64.22	65.08	96.79	96.84	96.72	77.06	72.03	71.75
	All	96.42	96.54	96.38	73.79	68.25	69.34	96.50	96.53	96.39	79.71	70.68	71.39
	Ch_Char	98.81	98.93	98.83	65.10	58.95	59.05	97.99	98.17	98.04	78.45	65.29	68.06
360	Ch_SF	98.87	99.02	98.89	71.59	63.88	64.79	99.05	99.16	99.07	74.82	70.67	70.97
	Ch_TLD	98.93	99.05	98.95	67.95	61.87	62.83	96.80	98.01	98.15	98.02	77.95	65.10
	Ch_BiGram	98.95	99.09	98.98	65.78	58.74	59.99	99.06	99.10	99.04	76.21	70.44	70.77
	All	97.95	98.15	98.01	75.17	65.84	67.51	99.06	99.15	99.07	77.35	72.07	72.36




图4-4 OSINT数据集上不同特征通道下PMAE相对MF增益效果柱状图




图4-5 360数据集上不同特征通道下PMAE相对MF增益效果柱状图

4.4 对比实验

4.4.1 对比方法选取

为了评估PMAE-DGA方法的效果，本研究使用一系列传统不平衡算法以及目前DGA检测不平衡学习领域的先进方法（SOTA方法）对其性能进行了评估，这些方法包括ROS、cost-sensitive、PQDO、LSTM.MI以及DeepDGA。

选取的不平衡优化算法如下：

（1）Random Oversampling（ROS）：通过随机复制少数类样本，增加少数类样本在数据集中的数量，使得少数类与多数类样本数量达到相对平衡的状态。

(2) **SMOTE**: 通过分析少数类样本的特征空间分布, 在少数类样本之间进行插值, 合成新的少数类样本, 增加少数类样本数量, 使得数据集的类别分布更加均衡。

(3) **Cost-Sensitive**: 在模型训练过程中为不同类别样本赋予相应的代价权重, 对误分类代价高的样本给予更高权重, 使模型更加关注这些样本的分类准确性, 从而优化模型决策边界, 有效降低整体误分类代价。

选取的SOTA方法如下:

(1) **PQDO**^[27]: 综合考虑样本的原始数量和特征属性, 通过迭代优化采样比例, 启发式地搜索最优解以实现重采样比例的动态优化。

(2) **LSTM.MI**^[28]: 对原始LSTM进行成本敏感型改进, 在反向传播学习过程中引入成本项动态调整各类别的分类权重, 以考虑类别之间的识别重要性。

(3) **DeepDGA**[6]: 使用成本敏感型深度学习架构, 利用字符级嵌入和深度学习架构自动提取域名特征, 引入成本项到反向传播过程中, 动态调整不同DGA家族的分类权重。

4.4.2 对比实验结果分析

OSINT数据集^[37]的对比实验数据在表4-7和表4-8中给出, 360数据集^[38]的对比实验数据在表4-9和表4-10中给出。

从实验数据来看, PAME-DGA方法显著提升了模型对难分类和稀有类的识别能力, 在保持高精度的情况下实现了更均衡的分类性能。在OSINT数据集上, Micro系列指标和Macro系列指标全面优于三种经典不平衡方法(ROS/SMOTE/Cost-Sensitive), 本文的方法将Macro-F1从最优的74.68%(Cost-Sensitive)提升到75.05%, Micro-F1从97.09%(Cost-Sensitive)提升到97.12%; 而相比SOTA方法(LSMT.PQDO/LSTM.MI/DeepDGA), Macro-F1相较表现最优的73.79%(DeepDGA)提升到75.05%, Micro-F1从最优的96.84%(DeepDGA)提升到97.12%。从具体家族分类数据来看, 针对样本量少于500的少数类别, 本文的方法也取得了突破性进展。以Volatile家族(238个样本)和Cryptowall家族(92个样本)为例, 相比经典不平衡方法, F1分数从SMOTE的89.72%提升到100%; 相比SOTA方法, 从LSMT.PQDO的86.87%提升到100%。Cryptowall家族上相比经典方法, F1从SMOTE的11.57%提升到32.56%(提升181%); 相比SOTA方法: 从LSTM.MI的7.41%提升到32.56%(提升339%)。

在360数据集上, 相比表现最优的经典不平衡方法Cost-Sensitive, 本文的方法将Macro-F1从70.01%提升到76.09%, Micro-F1也有小幅提升, 从99.10%提升到99.15%; 相比表现最优的SOTA方法DeepDGA, Macro-F1从73.26%提升到

76.09%，Micro-F1水平相当。另外，在360数据集上，对少数类家族样本的检测提升更为明显，对于Tofsee家族（仅20个样本），本文的方法首次实现有效检测（F1=100%），而所有对比方法（除DeepDGA达0.6667）均完全失效（F1=0）；针对Proslikefan家族（100个样本），本文的方法达到30%的F1分数，而所有对比方法均低于12.5%或完全失效。

综上，PAME-DGA在OSINT和360数据集上的综合性能均优于现有的经典不平衡处理方法和SOTA方法，充分证明了其对稀有类和难分类的识别精度的提升以及其在类别不平衡场景下的优势。

表4-7 OSINT数据集——与经典不平衡优化算法对比

DGA 家族类别	ROS			SMOTE			Cost-Sensitive			本文方法		
	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)
Geodo	56.11	98.06	71.38	55.98	100.0	71.78	56.91	100.0	72.54	58.55	98.26	73.38
Beebone	97.44	100.0	98.70	90.48	100.0	95.00	100.0	100.0	100.0	100.0	100.0	100.0
Murofet	82.36	87.91	85.04	88.03	82.90	85.39	88.69	88.36	88.52	86.97	88.57	87.76
Pykspa	61.46	82.61	70.48	57.49	76.45	65.63	82.02	79.35	80.66	80.43	77.66	79.02
Padcrypt	92.31	97.30	94.74	90.79	93.24	92.00	83.15	100.0	90.80	88.89	96.00	92.31
Ramnit	75.66	85.18	80.14	82.00	66.85	73.65	90.06	92.78	91.40	89.88	93.67	91.74
Volatile	75.76	44.64	56.18	94.12	85.71	89.72	100.0	94.64	97.25	100.0	100.0	100.0
Ranbyus	86.01	97.35	91.33	86.72	95.51	90.90	89.60	96.96	93.14	93.75	95.18	94.46
Qakbot	63.71	74.27	68.58	70.04	69.64	90.90	72.32	79.00	75.52	72.80	76.01	74.37
Simda	99.53	89.55	94.28	99.79	98.41	99.09	99.39	100.0	99.69	99.81	100.0	99.91
Rando	100.0	100.0	100.0	94.51	97.73	96.09	100.0	100.0	100.0	95.51	98.84	97.14
Suppobox	92.34	52.74	67.13	98.14	92.56	95.27	96.19	99.34	97.74	96.22	99.35	97.76
Locky	19.83	41.18	26.76	11.05	49.97	18.03	97.06	29.86	45.67	70.65	31.40	43.48
Tempedre	0.0	0.0	0.0	0.0	0.0	0.0	100.0	2.63	5.13	5.26	2.44	3.33
Qadars	86.85	93.43	90.02	76.19	92.93	83.73	99.43	87.37	93.01	96.64	93.50	95.04
Symmi	99.89	99.89	99.89	100.0	99.77	99.89	100.0	100.0	100.0	99.77	100.0	99.88
Banjori	99.96	99.82	99.89	100.0	99.99	99.99	99.99	100.0	100.0	99.99	99.99	99.99
Tinba	95.58	47.17	63.17	97.22	63.90	77.12	94.45	99.69	97.00	95.16	99.48	97.28
Hesperbot	0.92	2.86	1.39	1.18	14.29	2.19	50.0	5.71	10.26	15.38	5.26	7.84
Fobber	14.75	26.87	19.05	6.96	59.70	12.46	45.83	32.84	38.26	48.84	37.50	42.42
Dyre	100.0	100.0	100.0	99.60	100.0	99.27	25.0	6.37	10.15	100.0	100.0	100.0
Cryptowall	18.92	28.00	22.58	7.29	28.00	11.57	27.27	12.00	16.67	28.00	38.89	32.56
Corebot	97.14	100.0	98.55	98.55	100.0	99.27	100.0	100.0	100.0	100.0	98.21	99.10
Proslkefan	26.14	46.94	33.58	11.96	44.90	18.88	58.70	55.10	56.84	52.94	36.0	42.86
Bedep	24.44	32.35	27.85	5.81	29.41	9.71	90.00	26.47	40.91	8.33	2.86	4.26
Matsnu	77.91	95.71	85.90	92.65	90.00	91.30	88.89	91.43	90.14	100.0	91.86	95.76
Post	99.98	99.98	99.98	100.0	99.98	99.99	99.99	99.99	99.99	100.0	99.99	100.0
Necurs	95.66	84.28	89.61	96.88	83.08	89.45	96.15	87.52	91.63	97.22	86.20	91.38
Pushdo	73.02	88.20	79.90	76.39	92.70	83.76	90.86	89.33	90.08	89.62	94.80	92.13
Cryptolocker	19.94	40.45	26.72	10.76	48.31	17.60	75.00	21.91	33.91	35.37	34.12	34.73
Dircrypt	9.78	22.29	13.59	2.66	30.57	4.90	25.0	6.37	10.15	17.78	15.69	16.67
Shifu	65.57	97.75	78.49	88.64	95.51	90.90	96.36	97.55	96.95	96.01	99.21	97.58
Bamital	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0
Kraken	56.50	90.35	69.53	66.54	89.73	76.41	93.40	81.42	87.00	87.47	86.76	87.11
Nymaim	35.92	70.21	46.98	15.26	71.28	25.14	46.67	7.45	12.84	71.43	21.51	33.06
Shiotob	98.40	92.48	95.35	97.04	86.59	91.52	97.44	93.93	95.65	97.04	91.23	94.05
W32.Virut	0.0	0.0	0.0	0.0	0.0	0.0	100.0	94.64	97.25	68.75	91.67	78.57
Micro-avg	94.88	93.81	93.86	95.92	93.25	94.26	97.19	97.21	97.09	97.17	97.18	97.12
Macro-avg	64.84	70.54	66.13	64.07	73.79	65.67	83.32	74.09	74.68	76.88	75.19	75.05

表4-8 OSINT数据集——与SOTA方法对比

DGA 家族类别	LSMT.PQDO			LSTM.MI			DeepDGA			本文方法		
	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)
Geodo	55.68	100.0	71.53	47.97	68.93	56.57	56.91	100.0	72.54	58.55	98.26	73.38
Beebone	100.0	100.0	100.0	100.0	100.0	100.0	97.44	100.0	98.70	100.0	100.0	100.0
Murofet	87.89	82.18	84.93	91.76	82.19	86.71	84.93	89.95	87.37	86.97	88.57	87.76

第四章 实验分析

Pykspa	59.13	53.99	56.44	81.36	82.25	81.80	70.81	76.45	73.52	80.43	77.66	79.02
Padcrypt	75.00	40.54	52.63	51.75	100.0	68.20	92.00	93.24	92.62	88.89	96.00	92.31
Ramnit	89.22	87.73	88.47	88.48	89.51	88.99	89.44	91.61	90.51	89.88	93.67	91.74
Volatile	100.0	76.79	86.87	83.58	100.0	91.06	100.0	100.0	100.0	100.0	100.0	100.0
Ranbyus	89.79	94.90	92.27	79.32	97.85	87.61	93.89	94.74	94.31	93.75	95.18	94.46
Qakbot	72.96	69.00	70.93	67.38	81.02	73.57	72.57	71.88	72.22	72.80	76.01	74.37
Simda	98.91	99.98	99.44	99.68	99.96	99.82	99.64	99.45	99.54	99.81	100.0	99.91
Ramdo	81.72	86.36	83.98	100.0	100.0	100.0	98.85	97.73	98.29	95.51	98.84	97.14
Suppobox	92.18	95.40	93.76	97.00	98.91	97.94	96.16	98.69	97.41	96.22	99.35	97.76
Locky	97.92	21.27	34.94	55.83	30.32	39.30	91.89	30.77	46.10	70.65	31.40	43.48
Tempedre	0.0	0.0	0.0	0.0	0.0	0.0	12.50	2.63	4.35	5.26	2.44	3.33
Qadars	98.24	84.60	90.91	98.28	86.36	91.94	98.71	96.46	97.57	96.64	93.50	95.04
Symmi	99.89	100.0	99.94	100.0	99.77	99.89	99.89	100.0	99.94	99.77	100.0	99.88
Banjori	99.98	99.99	99.99	99.99	99.99	100.0	99.98	100.0	99.99	99.99	99.99	99.99
Tinba	93.07	98.17	95.55	93.31	96.32	94.79	91.19	98.51	94.71	95.16	99.48	97.28
Hesperbot	7.69	5.71	6.56	0.0	0.0	0.0	14.29	8.57	10.71	15.38	5.26	7.84
Fobber	17.65	26.87	21.30	22.22	8.96	12.77	44.00	32.84	37.61	48.84	37.50	42.42
Dyre	99.60	99.60	99.60	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0
Cryptowall	35.14	52.00	41.94	50.0	4.00	7.41	12.00	12.00	12.00	28.0	38.89	32.56
Corebot	100.0	98.53	99.26	100.0	100.0	100.0	100.0	98.53	99.26	100.0	98.21	99.10
Proslikefan	0.0	0.0	0.0	35.71	30.61	32.97	8.65	36.73	14.01	52.94	36.0	42.86
Bedep	16.85	44.12	24.39	71.43	29.41	41.67	52.38	32.35	40.00	8.33	2.86	4.26
Matsnu	96.77	85.71	90.91	83.33	92.86	87.84	88.16	95.71	91.78	100.0	91.86	95.76
Post	99.98	99.99	99.98	100.0	99.99	100.0	99.99	99.98	99.99	100.0	99.99	100.0
Necurs	96.94	84.86	90.50	96.34	81.84	88.50	96.77	86.87	91.55	97.22	86.20	91.38
Pushdo	67.87	84.27	75.19	89.47	85.96	87.68	86.39	82.02	84.15	89.62	94.80	92.13
Cryptolocker	10.85	67.98	18.72	38.46	33.71	35.93	47.93	32.58	38.80	35.37	34.12	34.73
Dircrypt	11.17	39.49	17.42	0.0	0.0	0.0	30.51	11.46	16.67	17.78	15.69	16.67
Shifu	95.60	97.75	96.66	91.81	98.57	95.07	95.39	97.34	96.36	96.01	99.21	97.58
Bamital	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0
Kraken	94.53	79.47	86.35	85.62	83.81	84.70	94.61	79.20	86.22	87.47	86.76	87.11
Nymaim	30.77	12.77	18.05	42.86	9.57	15.65	26.15	18.09	21.38	71.43	21.51	33.06
Shiotob	96.99	92.96	94.93	97.19	93.69	95.41	98.98	93.39	96.10	97.04	91.23	94.05
W32.Virut	66.67	11.76	20.00	42.31	64.71	51.16	58.62	100.0	73.91	68.75	91.67	78.57
Micro-avg	96.80	96.10	96.33	96.45	96.42	96.33	96.94	96.88	96.84	97.17	97.18	97.12
Macro-avg	71.26	69.59	67.68	72.50	71.11	70.13	75.72	74.59	73.79	76.88	75.19	75.05

表4-9 360数据集——与经典不平衡优化算法对比

DGA 家族类别	ROS			SMOTE			Cost-Sensitive			本文方法		
	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)
bamital	100.0	100.0	100.0	89.47	100.0	94.44	100.0	94.12	96.97	100.0	100.0	100.0
banjori	99.97	99.92	99.95	99.99	100.0	100.0	99.99	100.0	99.99	100.0	100.0	100.0
chinad	93.78	97.03	95.38	96.10	97.52	96.81	97.56	99.01	98.28	98.51	99.50	99.00
conficker	14.71	38.83	21.33	12.82	33.98	18.62	43.69	43.69	43.69	45.83	33.33	38.60
cryptolocker	6.55	45.96	11.46	4.23	55.05	7.86	61.90	45.96	52.75	51.58	57.00	54.16
dircrypt	14.22	32.22	19.73	0.84	24.44	1.63	50.0	13.33	21.05	46.67	7.53	12.96
dyre	100.0	100.0	100.0	100.0	100.0	100.0	99.53	98.61	99.07	100.0	99.50	99.75
emotet	99.99	99.98	99.98	99.99	99.97	99.98	99.98	100.0	99.99	99.99	100.0	99.99
fobber_v1	42.47	56.36	48.44	32.72	96.36	48.85	40.43	69.09	51.01	36.09	81.36	50.0
fobber_v2	29.13	47.62	36.14	21.05	95.24	34.48	63.16	19.05	29.27	18.35	85.00	30.18
gameover	99.67	99.17	99.42	99.67	99.25	99.46	100.0	98.92	99.46	99.87	99.46	99.67
gspy	100.0	100.0	100.0	81.82	100.0	90.00	100.0	77.78	87.50	100.0	100.0	100.0
locky	26.09	55.05	35.40	7.16	52.75	12.61	62.63	54.59	58.33	68.06	58.04	62.65
matsnu	69.82	95.68	80.73	85.48	98.15	91.38	97.42	93.21	95.27	95.63	96.15	95.89
murofet	77.47	88.19	82.48	87.75	75.61	81.23	91.17	85.00	87.98	87.90	86.75	87.32
necurs	74.66	87.05	80.38	53.57	86.32	66.11	95.80	82.93	88.90	96.81	85.16	90.61
nymaim	26.14	51.28	34.63	5.82	51.28	10.46	20.00	5.13	8.16	40.82	24.69	30.77
padcrypt	91.67	97.06	94.29	45.76	79.41	58.06	65.00	76.47	70.27	83.78	93.94	88.57
proslkefan	9.68	17.65	12.50	9.68	17.65	12.50	0.0	0.0	0.0	30.00	30.00	30.00
pykspa_v1	99.52	99.24	99.38	99.91	99.80	99.86	99.67	99.93	99.80	99.71	99.64	99.68
pykspa_v2_fake	6.78	39.73	11.58	2.73	45.89	5.15	37.27	56.16	44.81	40.61	58.13	47.81
pykspa_v2_real	0.0	0.0	0.0	1.06	7.89	1.87	0.0	0.0	0.0	15.00	7.50	10.00
qadars	66.54	95.05	78.28	95.43	97.53	96.47	99.44	96.98	98.19	99.15	97.50	98.32
ramnit	34.28	85.08	48.87	38.99	56.11	46.01	85.13	89.54	87.28	85.33	85.08	85.21
ranbyus	79.96	84.72	82.27	75.48	78.77	77.09	90.96	79.86	85.05	90.34	80.14	84.94
rovnix	99.97	99.40	99.68	99.99	99.63	99.81	99.94	99.89	99.92	99.99	99.78	99.88
shifu	95.81	97.86	96.82	94.74	98.05	96.37	93.35	98.25	95.73	96.94	99.22	98.07
simda	99.60	99.58	99.59	99.82	99.78	99.80	98.89	99.96	99.42	99.71	99.92	99.82
suppobox	86.18	99.16	92.22	94.41	95.40	94.90	96.48	91.63	93.99	95.91	97.91	96.90
symmi	99.88	95.59	97.69	100.0	99.65	99.83	100.0	100.0	100.0	100.0	100.0	100.0
tempedre	0.0	0.0	0.0	0.0	0.0	0.0	50.0	4.65	8.51	16.67	14.63	15.58
tinba	98.95	61.49	75.85	99.18	39.05	56.04	97.74	99.91	98.81	98.80	99.70	99.25

第四章 实验分析

tofsee	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	100.0	100.0	100.0
vawtrak	0.0	0.0	0.0	100.0	37.74	54.79	66.67	94.34	78.12	73.08	98.28	83.82
vidro	0.0	0.0	0.0	0.0	0.0	0.0	83.33	29.41	43.48	56.25	45.00	50.00
virut	99.37	86.94	92.74	99.50	78.98	88.06	99.10	99.75	99.43	99.50	99.95	99.72
Micro avg	97.94	95.44	96.10	97.98	93.01	94.18	99.10	99.16	99.10	99.21	99.14	99.15
Macro avg	59.52	68.14	61.87	59.31	69.37	59.46	74.62	69.37	70.01	76.86	78.33	76.09

表4-10 360数据集——与SOTA方法对比

DGA 家族类别	LSMT.PQDO			LSTM.MI			DeepDGA			本文的方法		
	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)	PRE (%)	REC (%)	F1 (%)
bamital	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0
banjori	99.99	100.0	100.0	100.0	100.0	100.0	99.99	100.0	100.0	100.0	100.0	100.0
chinad	95.24	99.01	97.09	96.62	99.01	97.80	98.54	100.0	99.26	98.51	99.50	99.00
conficker	46.88	14.56	22.22	33.33	28.16	30.53	36.08	33.98	35.00	45.83	33.33	38.60
cryptolocker	62.50	40.40	49.08	50.70	54.55	52.55	61.88	50.00	55.31	51.58	57.00	54.16
dircrypt	66.67	6.67	12.12	61.54	8.89	15.53	50.00	26.67	34.78	46.67	7.53	12.96
dyre	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0	99.50	99.75
emotet	99.97	100.0	99.98	99.98	100.0	99.99	99.98	100.0	99.99	99.99	100.0	99.99
fobber_v1	47.06	43.64	45.28	31.25	100.0	47.62	38.10	72.73	50.00	36.09	81.36	50.0
fobber_v2	0.0	0.0	0.0	0.0	0.0	0.0	38.82	52.38	44.59	18.35	85.00	30.18
gameover	99.83	99.13	99.48	100.0	99.00	99.50	99.71	99.38	99.54	99.87	99.46	99.67
gspy	90.00	50.00	64.29	100.0	83.33	90.91	94.74	100.0	97.30	100.0	100.0	100.0
locky	60.00	45.41	51.70	50.00	58.72	54.01	64.79	42.20	51.11	68.06	58.04	62.65
matsnu	97.48	95.68	96.57	91.43	98.77	94.96	97.39	91.98	94.60	95.63	96.15	95.89
murofet	80.07	91.38	85.35	89.47	88.00	88.73	86.78	91.48	89.07	87.90	86.75	87.32
necurs	89.94	83.35	86.52	94.30	83.11	88.35	94.65	86.74	90.52	96.81	85.16	90.61
nymaim	0.0	0.0	0.0	0.0	0.0	0.0	21.88	17.95	19.72	40.82	24.69	30.77
padcrypt	80.00	11.76	20.51	87.10	79.41	83.08	93.55	85.29	89.23	83.78	93.94	88.57
proslifean	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	30.00	30.00	30.00
pykspa_v1	99.78	99.88	99.83	99.59	99.69	99.64	99.57	99.81	99.69	99.71	99.64	99.68
pykspa_v2_fake	24.58	50.68	33.11	37.32	53.42	43.94	39.46	50.00	44.11	40.61	58.13	47.81
pykspa_v2_real	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	15.00	7.50	10.00
qadars	99.72	97.53	98.61	99.44	97.25	98.33	98.62	98.08	98.35	99.15	97.50	98.32
ramnit	83.97	88.56	86.20	84.28	91.85	87.90	87.01	89.93	88.45	85.33	85.08	85.21
ranbyus	86.50	80.06	83.15	95.68	70.24	81.01	91.38	78.87	84.66	90.34	80.14	84.94
rovnix	99.80	99.87	99.84	99.95	99.76	99.86	99.95	99.87	99.91	99.99	99.78	99.88
shifu	95.51	99.22	97.33	92.53	98.83	95.58	96.21	98.83	97.50	96.94	99.22	98.07
simda	99.48	99.88	99.68	99.58	99.84	99.71	99.38	99.96	99.67	99.71	99.92	99.82
suppobox	96.36	83.05	89.21	94.02	98.74	96.33	98.31	97.07	97.68	95.91	97.91	96.90
symmi	100.0	99.88	99.94	100.0	100.0	100.0	99.88	100.0	99.94	100.0	100.0	100.0
tempedreve	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	16.67	14.63	15.58
tinba	98.51	99.89	99.20	98.30	99.82	99.05	98.68	99.89	99.28	98.80	99.70	99.25
tofsee	0.0	0.0	0.0	0.0	0.0	0.0	50.0	100.0	66.67	100.0	100.0	100.0
vawtrak	76.79	81.13	78.90	75.00	84.91	79.65	74.07	75.47	74.77	73.08	98.28	83.82
vidro	100.0	29.41	45.45	100.0	23.53	38.10	50.0	29.41	37.04	56.25	45.00	50.0
virut	99.21	100.0	99.60	99.15	99.40	99.28	99.35	99.95	99.65	99.50	99.95	99.72
Micro avg	99.00	99.10	99.01	99.09	99.14	99.08	99.19	99.24	99.20	99.21	99.14	99.15
Macro avg	71.55	63.61	65.01	71.13	69.40	68.39	73.85	74.11	73.26	76.86	78.33	76.09

第五章 系统设计与实现

5.1 系统设计

5.1.1 系统需求分析

本系统旨在开发一个面向不平衡僵尸网络检测的生成机制敏感型预训练多通道自编码器DGA表征学习系统（PMAE-DGA），以有效检测DGA域名，提升对稀有和难分类DGA家族的检测性能。系统需求主要来源于现实网络安全领域对DGA域名检测的迫切需求。在当前网络环境中，DGA技术被广泛用于僵尸网络的通信，其生成的域名具有随机性和动态性，传统检测方法难以有效应对且现有方法大多忽视了数据集不平衡这一问题。

系统需要处理不平衡的数据集，因为不同DGA家族的样本数量差异巨大，这就要求系统能够在不平衡数据条件下进行有效的学习和检测。同时系统需要具备良好的可视化功能，以使用户直观地观察和分析实验结果，包括数据集分布、不同方法的性能对比等。

5.1.2 系统功能模块划分与功能描述

本系统前端界面划分与模型本身逻辑环环相扣，系统前端界面概要设计如图5-1所示，主要划分为以下几个功能模块：

（1）数据集展示模块：该模块负责展示所使用的数据集信息，包括OSINT数据集和360数据集。通过可视化的方式呈现数据集的DGA家族分布，如各家族的样本数量和占比，帮助用户直观了解数据集的整体情况。同时，提供数据集的详细统计信息，如总样本量等，为后续的数据处理和模型训练提供基础数据支持。

（2）多通道特征提取模块：此模块对两个原始数据集分别进行预处理操作，提取出多通道特征，并将处理后的数据集形式分别展示给用户，让用户对多通道特征构成有更清晰的理解。

（3）预训练表征模型模块：该模块实现对多通道特征的表征学习，提供权重参数选取可视化功能，帮助用户选择最优的模型参数。同时为清晰展示表征学习的增益，还将与多通道特征模型的对比结果可视化。

（4）检测器效果展示模块：该模块利用预训练好的表征模型对新的域名进行检测。通过与经典不平衡算法和SOTA方法进行对比实验，展示系统在不同数据集上的性能。提供详细的性能对比表和可视化图表，包括微平均F1值、宏平均F1值等指标，直观地显示系统在不同类别上的提升效果，以及与其他方法的优劣对比。




图5-1 系统前端界面概要设计

5.2 系统实现与测试

5.2.1 数据集分布展示模块

系统实现：用户首先进入前端导航页面选择功能，如图5-2。数据集展示模块基于HTML、CSS和JavaScript技术实现可视化展示。使用Chart.js库绘制柱状图，直观呈现数据集的DGA家族分布。

系统测试：达到预期效果，对于每个数据集，显示总样本量和各家族的样本数量及占比。柱状图按照数据集中DGA家族的样本数量从大到小排列，同时柱身颜色也由深到浅变化以突出柱状图中明显的长尾分布情况，从而让用户对数据集不均衡问题有更深刻的印象。另外设计了简洁美观的页面布局。页面中设置了清晰的标题和说明文字，方便用户理解数据含义。OSINT数据集^[37]DGA家族分布情况可视化界面如图5-3，360数据集^[38]DGA家族分布情况可视化界面如图5-4。

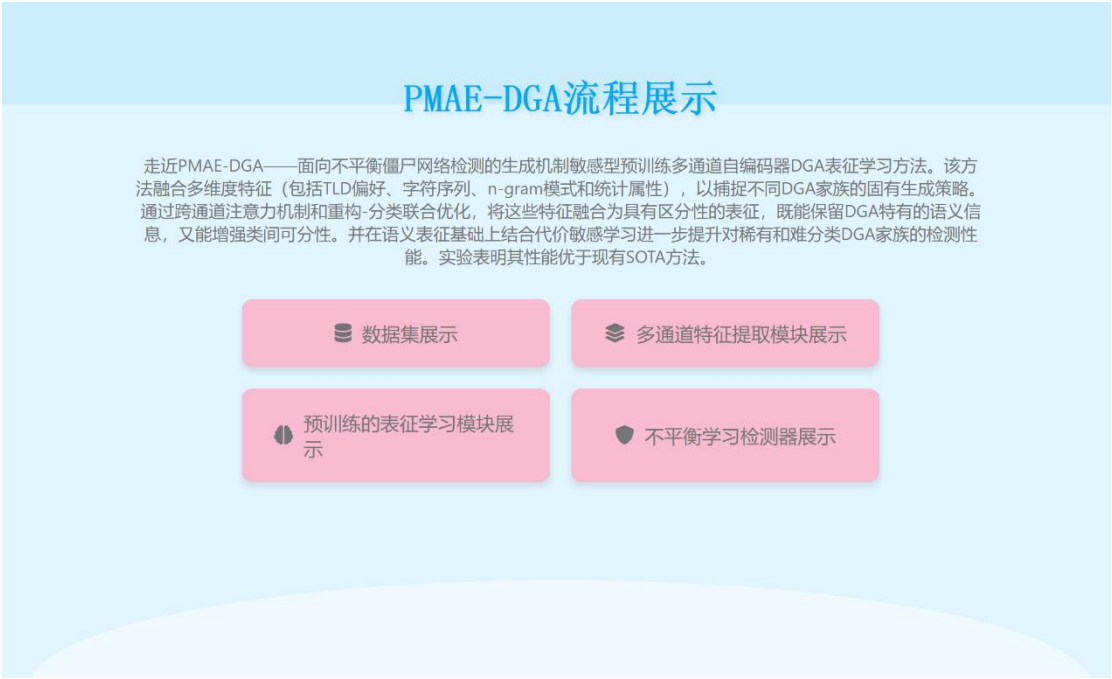


图5-2 前端初始导航界面




图5-3 OSINT数据集DGA家族分布可视化界面




图5-4 360数据集DGA家族分布可视化界面

5.2.2 多通道特征提取模块

系统实现：多通道特征提取模块对初始域名数据作预处理，旨在从域名数据中提取多种类型的特征，为后续的模式训练提供丰富的信息。该模块主要分为特征提取部分和前端展示部分，特征提取部分通过结合不同的特征提取方法提取出顶级域组合特征、高频Token特征以及n-gram语法特征等特征，提高模型对DGA域名的识别能力，部分核心代码如图5-5。前端展示部分通过app.py和multichannel_feature_extraction.html实现。app.py使用Flask框架构建Web界面，定义路由，处理数据集的分页索引，将提取的特征数据展示给用户。

系统测试：达到预期效果，用户进入初始导航页面后选择对应按钮后便可以选择数据集更清晰地查看感兴趣的数据，如图5-6所示；多通道特征提取模块展示页面下方设置有分页按钮，可使用“上一页”和“下一页”按钮进行分页操作，以便快速定位到感兴趣的数据区域，app.py中相关代码片段如图5-7。OSINT数据集提取的特征数据如图5-8，360数据集提取的特征数据如图5-9。

```
match_count += 1
match_char_count += len(substring)
matched_words.append(substring) # 收集匹配到的单词
#print("Matched English words:", matched_words)

# 计算有意义单词比例
meaningful_word_ratio = match_char_count / ntld_length if ntld_length > 0 else 0

stats = [
    domain_length, # 整个域名的长度
    ntld_length, # ntld长度
    tld_length, # tld长度
    contains_digit, # 是否含有数字
    all_digits,
    all_letters,
    round(digit_ratio, 3), # 数字占比
    round(letter_ratio, 3), # 字母占比
    round(special_char_ratio, 3), # 特殊字符占比
    round(hex_char_ratio, 3), # 十六进制字符占比
    round(vowel_ratio, 3), # 元音字母占比
    round(consonant_ratio, 3), # 辅音字母占比
    round(high_freq_ratio, 3), # 英文单词中高频字母占比
    round(low_freq_ratio, 3), # 英文单词中低频字母占比
    match_count, # 匹配到的英文单词次数
    round(meaningful_word_ratio, 3) # 有意义单词比例
]
```

图5-5 多通道特征提取部分核心代码



图5-6 多通道特征模块展示导航页面

5.2.3 预训练表征模型模块

系统实现：预训练表征模型模块在多通道特征的基础上，融合多通道特征并加入注意力机制与自编码器部分，旨在学习域名数据的有效表征，关键核心代码如图5-10。该模块分为表征学习模型部分和前端展示部分，通过前端界面展示不同权重下的模型效果和不同方法的对比结果。

系统测试：达到预期效果，表征学习模型展示导航界面如图5-11，用户可自主选择权重选择与增益效果展示。如图5-12，用户点击权重选择按钮后将跳转显示不同权重下预训练表征学习模型在两个数据集上的效果，并在最合适的权重上重点突出图例标志，以让用户对权重选取有更清晰的认知；用户选择增益效果按钮后可继续选择数据集，界面将根据用户的选择分别通过分组柱状图展示不同通道下的Micro F1 和Macro F1值，以实现多通道特征（MF）和预训练多通道融合表征学习（PMAE）在OSINT和360数据集上的效果对比，如图5-13和图5-14。

```
concatenated = Concatenate()([domain_lstm, feature_dense, token_lstm])
concatenated = tf.expand_dims(concatenated, axis=1)
concatenated = AttentionWeightedAverage2()(concatenated)

feature = Dense(units=64, activation='relu')(concatenated)
# x = Dense(64, activation='relu')(feature)
x = Dense(units=64, activation='relu')(feature)
softmax_out = Dense(labels_one_hot.shape[1], activation='softmax', name='softmax_out')(x)

# 新增AE层
feature_dense_encoded = Dense(units=32, activation='relu')(feature) # 中间编码层
feature_dense_decoded = Dense(units=64, activation='relu')(feature_dense_encoded) # 重构层

domain_lstm_encoded = Dense(units=32, activation='relu')(feature) # 中间编码层
domain_lstm_decoded = Dense(units=64, activation='relu')(domain_lstm_encoded) # 重构层

token_lstm_encoded = Dense(units=32, activation='relu')(feature) # 中间编码层
token_lstm_decoded = Dense(units=64, activation='relu')(token_lstm_encoded) # 重构层

domain_lstm_out = Concatenate(name='domain_lstm_out')([domain_lstm, domain_lstm_decoded])
token_lstm_out = Concatenate(name='token_lstm_out')([token_lstm, token_lstm_decoded])
feature_dense_out = Concatenate(name='feature_dense_out')([feature_dense, feature_dense_decoded])

loss_weights = {
    'softmax_out': LOSS_WEIGHT,
    'domain_lstm_out': 1 - LOSS_WEIGHT,
    'token_lstm_out': 1 - LOSS_WEIGHT,
    'feature_dense_out': 1 - LOSS_WEIGHT,
```

图5-10 表征学习自编码器部分核心代码



图5-11 表征学习模型展示导航界面




图5-12 权重参数选取可视化界面




图5-13 PMAE在OSINT数据集的增益效果界面




图5-14 PMAE在360数据集的增益效果界面

5.2.4 DGA检测器模块

系统实现：DGA检测器模块将表征学习后的数值型数据集输入各机器学习分类器，进一步加入不平衡优化算法（代价敏感学习）以提高检测效果。该模块分为检测器模型部分和前端展示部分，通过前端界面展示不同方法的性能对比结果。

系统测试：达到预期效果，用户选择检测器展示模块后可点击按钮自主选择数据集查看对应的总体性能对比或具体类别对比分析，如图5-15。点击后将跳转对应界面，OSINT和360数据集上PMAE-DGA方法与经典不平衡算法和SOTA方法的总体性能对比结果可视化界面分别如图5-16和图5-17。为了让用户更直观了解本文方法对少数类和难分类DGA家族的分类效果提升，本文还设置了在OS

INT和360数据集上针对特定类别分类效果的PMAE-DGA方法与经典不平衡算法和SOTA方法的对比结果可视化界面，分别如图5-18和图5-19。



图5-15 PMAE-DGA检测器展示导航界面




图5-16 OSINT数据集上的总体性能对比界面

不同方法总体性能对比 (360数据集)




图5-17 360数据集上的总体性能对比界面

细分各类别提升对比

与表现最佳的其他方法的性能对比
与表现最佳的其他方法的性能对比 (括号内为最佳其他方法)



详细性能对比表				
类别	最佳替代方法	最佳F1值	我们的方法F1值	提升
微平均	Cost-Sensitive	0.9709	0.9712	+0.0003
宏平均	Cost-Sensitive	0.7468	0.7505	+0.0037
Geodo	Cost-Sensitive/DeepDGA	0.7254	0.7338	+0.0084
Ramnit	Cost-Sensitive	0.9140	0.9174	+0.0034
Shifu	Cost-Sensitive	0.9695	0.9758	+0.0063
Tinba	Cost-Sensitive	0.9700	0.9728	+0.0028
Simda	Cost-Sensitive	0.9969	0.9991	+0.0022
Ranbyus	DeepDGA	0.9431	0.9448	+0.0015
Suppobox	Cost-Sensitive	0.9774	0.9776	+0.0002

图5-18 OSINT数据集上针对特定类别的性能对比界面



图5-19 360数据集上针对特定类别的性能对比界面

第六章 总结与展望

6.1 工作总结

本文针对现代僵尸网络中DGA（域名生成算法）域名的检测问题，提出了一种基于预训练多通道自编码器的DGA表征学习方法（PMAE-DGA）。通过对当前主流的DGA检测方法及其面临的挑战，尤其是类别不平衡问题进行了深度分析，本文提出了一种通过联合优化重构任务和分类任务的新型表征学习框架。该方法能够有效地捕捉不同DGA家族在生成策略上的细微差异，特别是在TLD偏好、多尺度序列模式及统计特征等多个维度上，提取并融合了DGA域名的关键语义信息。在实验验证方面，本文采用了OSINT DGA和360 DGA两个主流公开数据集，实验结果显示，PMAE-DGA方法显著提高了检测模型在Micro-F1和Macro-F1指标上的表现，尤其在少数类和难分类的识别方面表现出色。例如，Volatile和Cryptowall等难分类类别的F1指标提升幅度达到15.09%-240.50%，部分少数类类别的F1指标甚至达到了100%。此外，与经典的重采样方法（如ROS、SMOTE、Cost-Sensitive）及最新的SOTA方法（如LSTM.PQDO、LSTM.MI、DeepDGA）相比，PMAE-DGA方法的Macro-F1指标在OSINT DGA和360 DGA数据集上的提升分别达到了9.38和16.63个百分点，展示了其在处理不平衡类别问题中的优越性。

6.2 研究展望

尽管本文提出的方法在现有数据集上取得了显著的性能提升，但在特定类别（如新兴DGA家族或高度混淆的变种）上仍存在较大的误分类率，尤其是在样本分布不均衡场景下的少数类和特征模糊的难分类样本识别方面。未来研究可从以下多个维度深入探索：

（1）通过引入对比学习机制构建家族间的差异化表征空间，结合注意力机制增强关键特征的权重分配，从而帮助模型更精准地捕捉DGA家族间的语义差异，提升细粒度语义特征的学习能力。

（2）针对数据不平衡问题，可探索基于生成对抗网络（GAN）的少数类样本生成技术，或通过迁移学习实现跨数据集的特征复用，同时开发面向DGA领域特性的数据增强策略（如语义保持的域名变异规则）。

（3）在模型泛化能力方面，可以构建覆盖更广的跨领域评测基准，研究领域自适应方法以解决实际部署中的分布偏移问题。

（4）实际应用中的实时检测效率、对抗样本防御机制，以及与其他安全系统的协同分析框架也是值得重点关注的研究方向。

参考文献

- [1] Kwon J, Lee J, Lee H, et al. PsyBoG: A scalable botnet detection method for large-scale DNS traffic[J]. Computer Networks, 2016, 97: 48-73.
- [2] Bisio F, Saeli S, Lombardo P, et al. Real-time behavioral DGA detection through machine learning[C]//2017 International Carnahan Conference on Security Technology (ICCST) . IEEE, 2017: 1-6.
- [3] Fang X, Sun X, Yang J, et al. Domain-embeddings based DGA detection with incremental training method[C]//2020 IEEE Symposium on Computers and Communications (ISCC) . IEEE, 2020: 1-6.
- [4] Zang X, Gong J, Zong P. Identifying DGA malware via behavior analysis[C]//2021 IEEE Wireless Communications and Networking Conference (WCNC) . IEEE, 2021: 1-6.
- [5] Lei K, Fu Q, Ni J, et al. Detecting malicious domains with behavioral modeling and graph embedding[C]//2019 IEEE 39th International Conference on Distributed Computing Systems (ICDCS) . IEEE, 2019: 601-611.
- [6] Vinayakumar R, Soman K P, Poornachandran P. Deepdga-minet: Cost-sensitive deep learning based framework for handling multiclass imbalanced dga detection[J]. Handbook of Computer Networks and Cyber Security: Principles and Paradigms, 2020: 905-928.
- [7] Antonakakis M, Perdisci R, Nadji Y, et al. From {Throw-Away} traffic to bots: Detecting the rise of {DGA-Based} malware[C]//21st USENIX Security Symposium (USENIX Security 12) . 2012: 491-506.
- [8] Wang T S, Lin H T, Cheng W T, et al. DBod: Clustering and detecting DGA-based botnets using DNS traffic analysis[J]. Computers & Security, 2017, 64: 1-15.
- [9] Schüppen S, Teubert D, Herrmann P, et al. {FANCI}: Feature-based automated {NXDomain} classification and intelligence[C]//27th USENIX Security Symposium (USENIX Security 18) . 2018: 1165-1181.
- [10] Alaeiyan M, Parsa S, Conti M. Detection of algorithmically-generated domains: An adversarial machine learning approach[J]. Computer Communications, 2020, 160: 661-673.
- [11] Drichel A, Faerber N, Meyer U. First step towards explainable dga multiclass classification[C]//Proceedings of the 16th International Conference on Availability, Reliability and Security. 2021: 1-13.
- [12] AlSabeh A, Friday K, Kfoury E, et al. On dga detection and classification using p4 programmable switches[J]. Computers & Security, 2024, 145: 104007.

-
- [13] Woodbridge J, Anderson H S, Ahuja A, et al. Predicting domain generation algorithms with long short-term memory networks[J]. arxiv preprint arxiv:1611.00791, 2016.
 - [14] Lison P, Mavroeidis V. Automatic detection of malware-generated domains with recurrent neural models[J]. arxiv preprint arxiv:1709.07102, 2017.
 - [15] Curtin R R, Gardner A B, Grzonkowski S, et al. Detecting DGA domains with recurrent neural networks and side information[C]//Proceedings of the 14th international conference on availability, reliability and security. 2019: 1-10.
 - [16] Huang J, Wang P, Zang T, et al. Detecting domain generation algorithms with convolutional neural language models[C]//2018 17th IEEE International Conference On Trust, Security And Privacy In Computing And Communications/12th IEEE International Conference On Big Data Science And Engineering (TrustCom/BigDataSE) . IEEE, 2018: 1360-1367.
 - [17] Xu C, Shen J, Du X. Detection method of domain names generated by DGAs based on semantic representation and deep neural network[J]. Computers & Security, 2019, 85: 77-88.
 - [18] Highnam K, Puzio D, Luo S, et al. Real-time detection of dictionary dga network traffic using deep learning[J]. SN Computer Science, 2021, 2 (2) : 110.
 - [19] Liang J, Chen S, Wei Z, et al. HAGDetector: Heterogeneous DGA domain name detection model[J]. Computers & Security, 2022, 120: 102803.
 - [20] Ravi V, Alazab M, Srinivasan S, et al. Adversarial defense: DGA-based botnets and DNS homographs detection through integrated deep learning[J]. IEEE Transactions on Engineering Management, 2021, 70 (1) : 249-266.
 - [21] Tuan T A, Long H V, Taniar D. On detecting and classifying DGA botnets and their families[J]. Computers & Security, 2022, 113: 102549.
 - [22] Zhao K, Guo W, Qin F, et al. D3-SACNN: DGA domain detection with self-Attention convolutional network[J]. IEEE Access, 2021, 10: 69250-69263.
 - [23] Ding L, Du P, Hou H, et al. Botnet DGA domain name classification using transformer network with hybrid embedding[J]. Big Data Research, 2023, 33: 100395.
 - [24] Chawla N V, Bowyer K W, Hall L O, et al. SMOTE: synthetic minority over-sampling technique[J]. Journal of Artificial Intelligence Research, 2002, 16: 321-357.
 - [25] Zhang Z, Pfister T. Learning fast sample re-weighting without reward data[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 725-734.

-
- [26] Chen Y, Pang B, Shao G, et al. DGA-based botnet detection toward imbalanced multiclass learning[J]. Tsinghua Science and Technology, 2021, 26 (4) : 387-402.
- [27] Tran D, Mac H, Tong V, et al. A LSTM based framework for handling multiclass imbalance in DGA botnet detection[J]. Neurocomputing, 2018, 275: 2401-2413.
- [28] Simran K, Balakrishna P, Vinayakumar R, et al. Deep learning based frameworks for handling imbalance in DGA, Email, and URL Data Analysis[C]//Computational Intelligence, Cyber Security and Computational Models. Models and Techniques for Intelligent Systems and Automation: 4th International Conference, ICC3 2019, Coimbatore, India, December 19–21, 2019, Revised Selected Papers 4. Springer Singapore, 2020: 93-104.
- [29] Hu X, Li M, Cheng G, et al. Towards Accurate DGA Detection based on Siamese Network with Insufficient Training Samples[C]//ICC 2022-IEEE International Conference on Communications. IEEE, 2022: 2670-2675.
- [30] Fan B, Ma H, Liu Y, et al. KDTM: Multi-Stage Knowledge Distillation Transfer Model for Long-Tailed DGA Detection[J]. Mathematics, 2024, 12 (5) : 626.
- [31] Almashhadani A O, Kaiiali M, Carlin D, et al. MaldomDetector: A system for detecting algorithmically generated domain names with machine learning[J]. Computers & Security, 2020, 93: 101787.
- [32] Park K H, Song H M, Do Yoo J, et al. Unsupervised malicious domain detection with less labeling effort[J]. Computers & Security, 2022, 116: 102662.
- [33] Plohmman D, Yakdan K, Klatt M, et al. A comprehensive measurement study of domain generating malware[C]//25th USENIX Security Symposium (USENIX Security 16) . 2016: 263-278.
- [34] Hu X, Chen H, Li M, et al. ReplaceDGA: BiLSTM-based adversarial DGA with high anti-detection ability[J]. IEEE Transactions on Information Forensics and Security, 2023, 18: 4406-4421.
- [35] Public Suffix List. Public Suffix List Dataset [EB/OL].[2024-12-08]. https://publicsuffix.org/list/public_suffix_list.dat.
- [36] CHENNY. english-word-10000: A list of 10,000 English words [EB/OL]. [2024-12-11]. <https://github.com/chenny/english-word-10000>.
- [37] BAMBENEK Consulting. C2 Domain Blocklists [EB/OL]. [2024]. <http://osint.bambenekconsulting.com/feeds/>.
- [38] 360 NETLAB. DGA 恶意域名检测数据集 [EB/OL]. [2024]. <https://data.netlab.360.com/dga/>.

- [39] Sivaguru R, Choudhary C, Yu B, et al. An evaluation of DGA classifiers[C]//2018 IEEE International Conference on Big Data. IEEE, 2018: 5058-5067.
- [40] Hwang C, Kim H, Lee H, et al. Effective dga-domain detection and classification with textcnn and additional features[J]. Electronics, 2020, 9 (7) : 1070.
- [41] Kostopoulos N, Kalogeras D, Pantazatos D, et al. SHAP interpretations of tree and neural network DNS classifiers for analyzing DGA family characteristics[J]. IEEE Access, 2023, 11: 61144-61160.
- [42] Schiavoni S, Maggi F, Cavallaro L, et al. Phoenix: DGA-based botnet tracking and intelligence[C]//International Conference on detection of intrusions and malware, and vulnerability assessment. Cham: Springer International Publishing, 2014: 192-211.
- [43] Curtin R R, Gardner A B, Grzonkowski S, et al. Detecting DGA domains with recurrent neural networks and side information[C]//Proceedings of the 14th international conference on availability, reliability and security. 2019: 1-10.

致谢

落笔至此，我的本科生涯也将至尾声，无尽感慨与喟叹学生时光悄然而逝，同时也对这段路途上给予我帮助与支持的老师和同学满怀谢意。

首先，非常感谢我的导师邵国林老师在论文写作期间给予我的悉心指导。老师认真负责，良师如益友，让我收获颇多。同时，我也要感谢曾经为我们授课的每一位老师，正是他们的悉心教导，让我得以不断学习和充盈专业知识。最后，感谢我的家人朋友在论文写作期间带给我的支持与鼓励。

愿未来能恣意洒脱，不受世事束缚。人生似旷野，我要迈向下一篇章啦。